



Ch2

贝叶斯决策理论

任课教师：柳欣老师

email: starxliu@163.com

Bayes, Thomas(1702—1761)

贝叶斯是英国数学家.1702年生于伦敦;

1761年4月17日卒于坦布里奇韦尔斯.

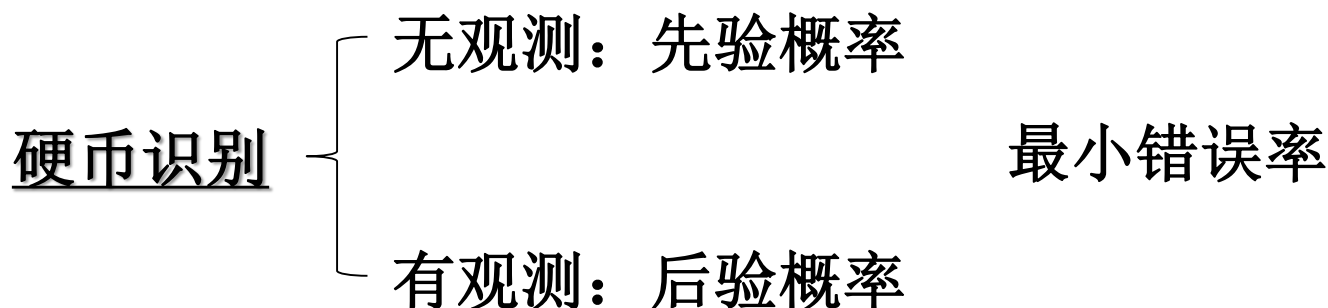


贝叶斯是一位自学成才的数学家.曾助理宗教事务, 后来长期担任坦布里奇韦尔斯地方教堂的牧师.1742年, 贝叶斯被选为英国皇家学会会员.

如今在概率、数理统计学中以贝叶斯姓氏命名的有贝叶斯公式、贝叶斯风险、贝叶斯决策函数、贝叶斯决策规则、贝叶斯估计量、贝叶斯方法、贝叶斯统计等等.

2.1 引言

- 统计决策理论是处理模式分类问题的基本理论之一
- 贝叶斯 (**Bayes**) 决策理论是统计模式识别中一个基本方法



贝叶斯公式：
$$P(\omega_i | x) = \frac{p(x, \omega_i)}{p(x)} = \frac{P(\omega_i)p(x | \omega_i)}{p(x)}, i = 1, 2$$

2.1 引言

问题描述

- 样本与样本空间： d 维特征向量

$$\mathbf{x} = [x_1, x_2, \dots, x_d]^T \quad \mathbf{x} \in R^d$$

- 类别与类别空间： C 类

$$\Omega = \{\omega_1, \omega_2, \dots, \omega_i, \dots, \omega_c\}$$

前提

(1) 各类总体的概率分布是已知的;

(2) 类别数是一定的

- $P(\omega_i)$ 和 $P(\mathbf{x}|\omega_i)$ 已知

- 现观察到一个特征向量 \mathbf{x} , \mathbf{x} 分到哪一类最合理??



2.1 引言

贝叶斯推理就是在不完全情报下，**对部分未知的状态用主观概率估计**，然后用贝叶斯公式对先验概率进行修正，最后再利用修正概率做出最优决策。

贝叶斯决策理论方法是统计决策中的一个基本方法，其基本思想是：

- 1、已知条件概率密度参数表达式和先验概率。
- 2、利用贝叶斯公式转换成后验概率。
- 3、根据后验概率大小进行决策分类。

2.1 引言

○ 分类错误率

- 条件错误率（样本 \mathbf{x} 上）为：

$$P(e | \mathbf{x}) = \begin{cases} P(\omega_2 | \mathbf{x}) = 1 - P(\omega_1 | \mathbf{x}) & \text{若决定 } \mathbf{x} \in \omega_1 \\ P(\omega_1 | \mathbf{x}) = 1 - P(\omega_2 | \mathbf{x}) & \text{若决定 } \mathbf{x} \in \omega_2 \end{cases}$$

- （平均）错误率（所有独立样本上条件错误率的期望）：

$$P(e) = E(P(e | \mathbf{x})) = \int_{-\infty}^{\infty} P(e | \mathbf{x}) p(\mathbf{x}) d\mathbf{x}$$

2.2 几种常用的决策规则

2.2.1 基于最小错误率的贝叶斯决策

○ 例子：癌细胞的识别

- ω_1 正常细胞, ω_2 异常细胞 (状态, 随机变量)
- 先验概率: $P(\omega_1), P(\omega_2)$, $P(\omega_1) + P(\omega_2) = 1$

○ 只使用先验概率决策的情况:


$$\left. \begin{array}{l} P(\omega_1) > P(\omega_2), x \in \omega_1 \\ P(\omega_1) < P(\omega_2), x \in \omega_2 \end{array} \right\} \text{这种分类器决策无意义}$$

奇怪的结果, 需要利用观测信息 (胞核总光密度, $d=1$)

$$P(\omega_1/x) \qquad P(\omega_2/x)$$

2.2.1 基于最小错误率的贝叶斯决策

- 类条件概率密度: $P(x/\omega_i) \quad i=1,2,\dots$




2.2.1 基于最小错误率的贝叶斯决策

- 利用贝叶斯公式

$$P(\omega_i | x) = \frac{p(x | \omega_i)P(\omega_i)}{p(x)} = \frac{p(x | \omega_i)P(\omega_i)}{\sum_{j=1}^2 p(x | \omega_j)P(\omega_j)}, i = 1, 2$$

得到的条件概率称为状态的后验概率



2.2.1 基于最小错误率的贝叶斯决策

基于最小错误率的贝叶斯决策规则

$$\begin{cases} \text{若 } P(\omega_1/x) > P(\omega_2/x), \text{ 则 } x \in \omega_1 \\ \text{若 } P(\omega_1/x) < P(\omega_2/x), \text{ 则 } x \in \omega_2 \end{cases}$$

等价形式:

$$(1) \quad \text{If } P(\omega_i | x) = \max_{j=1,2} P(\omega_j | x), \text{ then } x \in \omega_i$$

$$(2) \quad \text{If } p(x | \omega_i)P(\omega_i) = \max_{j=1,2} p(x | \omega_j)P(\omega_j), \text{ then } x \in \omega_i$$

$$(3) \quad \text{If } l(x) = \frac{p(x | \omega_1)}{p(x | \omega_2)} > \frac{P(\omega_2)}{P(\omega_1)}, \text{ then } x \in \begin{cases} \omega_1 \\ \omega_2 \end{cases}$$

$$(4) \quad h(x) = -\ln[l(x)] = -\ln p(x | \omega_1) + \ln p(x | \omega_2)$$

$$\text{If } h(x) < \ln\left(\frac{P(\omega_1)}{P(\omega_2)}\right), \text{ then } x \in \begin{cases} \omega_1 \\ \omega_2 \end{cases}$$

$$1, \quad l(x): \text{ 似然比}, \quad \frac{P(\omega_2)}{P(\omega_1)}: \text{ 似然比阈值}, \quad h(x): \text{ 对数似然比}$$

2.2.1 基于最小错误率的贝叶斯决策

有两个可选的假设：

病人有癌症(cancer)、病人无癌症(normal)

可用数据来自化验结果：正+和负-

有先验知识：在所有人口中，患病率是0.8%

对确实有病的患者的化验准确率为98%，

对确实无病的患者的化验准确率为97%，

总结如下

$$P(\text{cancer})=0.008, P(\text{normal})=0.992$$

$$P(+|\text{cancer})=0.98, P(-|\text{cancer})=0.02$$

$$P(+|\text{normal})=0.03, P(-|\text{normal})=0.97$$

问题：假定有一个新病人，化验结果为正，是否应将病人断定为有癌症？求后验概率 $P(\text{cancer}|+)$ 和 $P(\text{normal}|-)$

例子

因此极大后验假设计算如下：

$$P(+|\text{cancer})P(\text{cancer})=0.00784$$

$$P(+|\text{normal})P(\text{normal})=0.02976$$

$$P(\text{cancer}|+)=0.00784/(0.00784+0.02976)=0.21$$

$$P(-|\text{cancer})P(\text{cancer})=0.00016$$

$$P(-|\text{normal})P(\text{normal})=0.96224$$

$$P(\text{normal}|-)=0.96224/(0.00016+0.96224)=0.99834$$

贝叶斯推理的结果很大程度上依赖于先验概率，另外不是完全接受或拒绝假设，只是在观察到较多的数据后增大或减小了假设的可能性。

2.2.1 基于最小错误率的贝叶斯决策

◆ 例2.1 根据已有知识和经验，两类的先验概率为：

➤ 正常(ω_1): $P(\omega_1)=0.9$

➤ 异常(ω_2): $P(\omega_2)=0.1$

➤ 对某一样本观察值 \mathbf{x} ，通过计算或查表得到：

$$p(\mathbf{x}|\omega_1)=0.2, \quad p(\mathbf{x}|\omega_2)=0.4$$

$$P(\omega_1 | \mathbf{x}) = \frac{P(\omega_1) p(\mathbf{x} | \omega_1)}{\sum_{j=1}^2 P(\omega_j) p(\mathbf{x} | \omega_j)} = \frac{0.9 \times 0.2}{0.9 \times 0.2 + 0.1 \times 0.4} = 0.818$$

$$P(\omega_2 | \mathbf{x}) = \frac{P(\omega_2) p(\mathbf{x} | \omega_2)}{\sum_{j=1}^2 P(\omega_j) p(\mathbf{x} | \omega_j)} = \frac{0.4 \times 0.1}{0.2 \times 0.9 + 0.4 \times 0.1} = 0.182$$

2.2.1 基于最小错误率的贝叶斯决策

○ 分类错误率最小的证明（一维）

- 条件错误率（样本 \mathbf{x} 上）为：


$$\begin{aligned} P(e | \mathbf{x}) &= \begin{cases} P(\omega_2 | \mathbf{x}) = 1 - P(\omega_1 | \mathbf{x}) & \text{若决定 } \mathbf{x} \in \omega_1 \\ P(\omega_1 | \mathbf{x}) = 1 - P(\omega_2 | \mathbf{x}) & \text{若决定 } \mathbf{x} \in \omega_2 \end{cases} \\ &= 1 - \max_i P(\omega_i | \mathbf{x}) \end{aligned}$$

- （平均）错误率（所有独立样本上条件错误率的期望）：

$$P(e) = E(P(e | \mathbf{x})) = \int_{-\infty}^{\infty} P(e | \mathbf{x}) p(\mathbf{x}) d\mathbf{x}$$

2.2.1 基于最小错误率的贝叶斯决策

- 设 t 为两类的分界面，则在特征向量 x 是一维时， $t=x_0$ 为 x 轴上的一点。形成两个决策区域： $R_1 \sim (-\infty, t)$ 和 $R_2 \sim (t, +\infty)$




$R_1(\rightarrow \omega_1)$ and $R_2(\rightarrow \omega_2)$

2.2.1 基于最小错误率的贝叶斯决策

- 设 t 为两类的分界面，则在特征向量 x 是一维时， $t=x_0$ 为 x 轴上的一点。形成两个决策区域： $R_1 \sim (-\infty, t)$ 和 $R_2 \sim (t, +\infty)$


$$\begin{aligned} P(e) &= P(x \in R_1, \omega_2) + P(x \in R_2, \omega_1) \\ &= P(\omega_2)P(x \in R_1 | \omega_2) + P(\omega_1)P(x \in R_2 | \omega_1) \\ &= P(\omega_2) \int_{R_1} p(x | \omega_2) dx + P(\omega_1) \int_{R_2} p(x | \omega_1) dx \\ &= P(\omega_2)P_2(e) + P(\omega_1)P_1(e) \end{aligned}$$

2.2.1 基于最小错误率的贝叶斯决策



- **Bayes**最小错误率决策使得每个观测值下的条件错误率最小，因而保证了（平均）错误率最小。
- **Bayes**决策是一致最优决策

2.2.1 基于最小错误率的贝叶斯决策



2.2.1 基于最小错误率的贝叶斯决策

○ 多类决策规则:

(1) If $P(\omega_i | x) = \max_{j=1, \dots, c} P(\omega_j | x)$, then $x \in \omega_i$

(2) If $p(x | \omega_i)P(\omega_i) = \max_{j=1, \dots, c} p(x | \omega_j)P(\omega_j)$, then $x \in \omega_i$

● 计算正确分类概率更简单

$$P(e) = 1 - P(c) = 1 - \sum_{j=1}^c \int_{\mathcal{R}_j} p(x | \omega_j) dx$$

2.2 几种常用的决策规则

2.2.2 基于最小风险的贝叶斯决策

- 风险：错误判断所造成的损失的严重程度
- 例子：癌细胞的识别
 - 没病(正常 ω_1)被判为有病(异常 ω_2)，还可以做进一步检查，损失不大；
 - 有病(ω_2)被判为无病(ω_1)，错过诊治时机，损失严重
- 决策（行动）空间

$$\mathcal{A} = \{\alpha_1, \alpha_2, \dots, \alpha_i, \dots, \alpha_a\}$$

- 损失函数 一决策表或损失矩阵 $(\lambda_{i,j})_{N \times N}$
 $\lambda(\alpha_i, \omega_j), \quad i = 1, 2, \dots, a; j = 1, 2, \dots, c$

2.2.2 基于最小风险的贝叶斯决策

- 基于**最小风险**的贝叶斯决策：决策有代价，选择风险最小的决策

- 条件期望损失（条件风险）—特定 x

$$R(\alpha_i | x) = E[\lambda(\alpha_i, \omega_j) | x] = \sum_{j=1}^c \lambda(\alpha_i, \omega_j) P(\omega_j | x), \quad i = 1, 2, \dots, a$$

- 期望风险 —整个特征空间

$$R(\alpha) = \int R[\alpha(x) | x] p(x) dx$$

2.2.2 基于最小风险的贝叶斯决策

- 贝叶斯最小风险决策，通过保证每个观测值下决策的条件风险最小，使得它的期望风险最小，是一致最优决策
- 最小风险的贝叶斯决策规则

$$\text{if } R(\alpha_k | x) = \min_{i=1,2,\dots,a} R(\alpha_i | x), \text{ then } \alpha = \alpha_k$$

- 计算步骤

- (1) 计算后验概率
$$P(\omega_j | x) = \frac{P(\omega_j)p(x | \omega_j)}{\sum_{i=1}^c P(\omega_i)p(x | \omega_i)}$$

- (2) 计算风险

$$R(\alpha_i | x) = \sum_{j=1}^c \lambda(\alpha_i, \omega_j) P(\omega_j | x), \quad i = 1, 2, \dots, a$$

- (3) 决策

$$\alpha = \arg \min_{i=1,2,\dots,a} R(\alpha_i | x)$$

2.2.2 基于最小风险的贝叶斯决策

例2.2 细胞识别——最小风险决策

- 正常(ω_1): $P(\omega_1)=0.9$
- 异常(ω_2): $P(\omega_2)=0.1$
- 对某一样本观察值 x , 通过计算或查表得到:
 $p(x|\omega_1)=0.2, p(x|\omega_2)=0.4$
- $\lambda_{11}=0, \lambda_{12}=6, \lambda_{21}=1, \lambda_{22}=0$

- 后验概率: $P(\omega_1|x)=0.818, P(\omega_2|x)=0.182$

$$R(\alpha_1 | x) = \sum_{j=1}^2 \lambda_{1j} P(\omega_j | x) = \lambda_{12} P(\omega_2 | x) = 1.092$$

$$R(\alpha_2 | x) = \sum_{j=1}^2 \lambda_{2j} P(\omega_j | x) = \lambda_{21} P(\omega_1 | x) = 0.818$$

$$j = \operatorname{argmin}_i R(\omega_i | \mathbf{x}) = 2 \quad \mathbf{x} \in \omega_2$$


2.2.2 基于最小风险的贝叶斯决策

- 最小风险贝叶斯决策除须已知先验概率、类条件概率，还需要有合适的损失函数，要求更多先验知识
- 最小错误率贝叶斯决策就是在**0-1损失函数**条件下的最小风险贝叶斯决策（特例）

$$\lambda(\alpha_i, \omega_j) = \begin{cases} 1 & i = j \\ 0 & i \neq j \end{cases} \quad i, j = 1, 2, \dots, c$$

$$R(\alpha_i | x) = \sum_{j=1}^c \lambda(\alpha_i, \omega_j) P(\omega_j | x)$$

$$= \sum_{j=1, j \neq i}^c P(\omega_j | x) = 1 - P(\omega_i | x)$$



2.2.3 其它决策方法

- 损失函数无法确定，在限定一类错误率条件下，使另一类错误率为最小的两类决策（**neyman-pearson**决策）

$$P(\omega_2)P_2(e) + P(\omega_1)P_1(e) \Rightarrow P_2(e) = \varepsilon_0$$

用 Lagrange 乘子法：

$$\min \quad L = P_1(e) + \lambda(P_2(e) - \varepsilon) \quad (\text{对分类边界和 } \lambda \text{ 求最小})$$

$$\begin{aligned} &= \int_{R_2} p(x | \omega_1) dx + \lambda \left(\int_{R_1} p(x | \omega_2) dx - \varepsilon \right) \\ &= 1 - \int_{R_1} p(x | \omega_1) dx + \lambda \left(\int_{R_1} p(x | \omega_2) dx - \varepsilon \right) \\ &= (1 - \lambda \varepsilon) + \int_{R_1} [\lambda p(x | \omega_2) - p(x | \omega_1)] dx \end{aligned}$$

为了求极值点， L 对边界 t 和 λ 求偏导数，并令其为0.

$$\frac{\partial L}{\partial t} = 0 \Rightarrow \lambda^* = \frac{p(t^* | \omega_1)}{p(t^* | \omega_2)}$$

$$\frac{\partial L}{\partial \lambda} = 0 \Rightarrow \int_{R_1^*} p(x | \omega_2) dx$$


- 决策规则 $\text{if } \frac{p(x/\omega_1)}{p(x/\omega_2)} > \lambda \text{ then } x \in \omega_1$
 $\text{if } \frac{p(x/\omega_1)}{p(x/\omega_2)} < \lambda \text{ then } x \in \omega_2$

2.2.3 其它决策方法

最小最大决策

- 先验概率 $P(\omega_i)$ 可变或未知情况下，风险最小

$$R = a + bP(\omega_1)$$



- 选择使最小贝叶斯风险为最大值时的来设计分类器
- 最小最大决策是偏于保守的方法，是最坏的贝叶斯风险

两类错误率与ROC曲线

两类错误率

- 阳性（Positive）、阴性（Negative）
- 真阳性（TP）、假阳性（FP、Type-I Error、误报、虚警）
- 真阴性（TN）、假阴性（FN、Type-II Error、漏报）

- 灵敏度 $Sn = \frac{TP}{TP + FN}$

真正类率(True Positive Rate)

- 特异度 $Sp = \frac{TN}{TN + FP}$

负正类率(False Positive Rate)FPR


ROC曲线

接收者操作特征
(receiver operating characteristic)

AUC

(Area under Curve): Roc曲线下的面积, 介于0.1和1之间。Auc作为数值可以直观的评价分类器的好坏, 值越大越好。

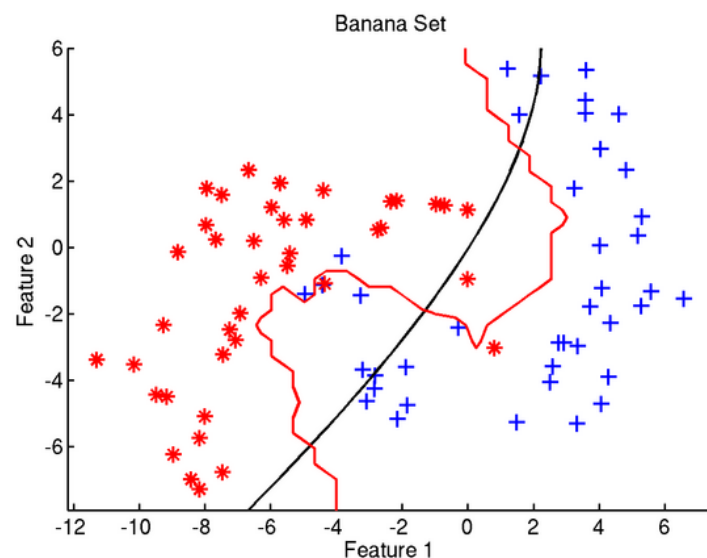
		预测		
		1	0	合计
实际	1	True Positive TP	False Negative FN	Actual Positive (TP+FN)
	0	False Positive FP	True Negative TN	Actual Negative (FP+TN)
合计		Predicted Positive (TP+FP)	Predicted Negative (FN+TN)	TP+FN+FP+TN



2.2.4 分类器设计

- 特征空间 $\xrightarrow{\text{决策规则}}$ 决策区域
- 决策面：决策域的边界面
- 决策面方程：解析形式
- 判决函数：表达决策规则的一组函数

$$g_i(x), i = 1, 2, \dots, c$$



2.2.4 分类器设计

多类情况

决策规则

if $g_j(x) = \max_i \{g_i(x)\}$ then $x \in \omega_j$

$$j = \operatorname{argmax}_i g_i(x)$$

判别函数

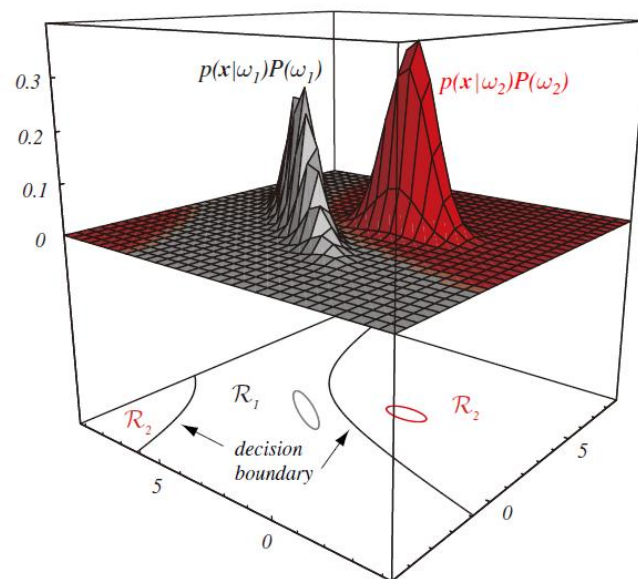

$$g_i(x) = P(\omega_i | x)$$

$$g_i(x) = p(x | \omega_i)P(\omega_i)$$

$$g_i(x) = \ln p(x | \omega_i) + \ln P(\omega_i)$$

决策面方程

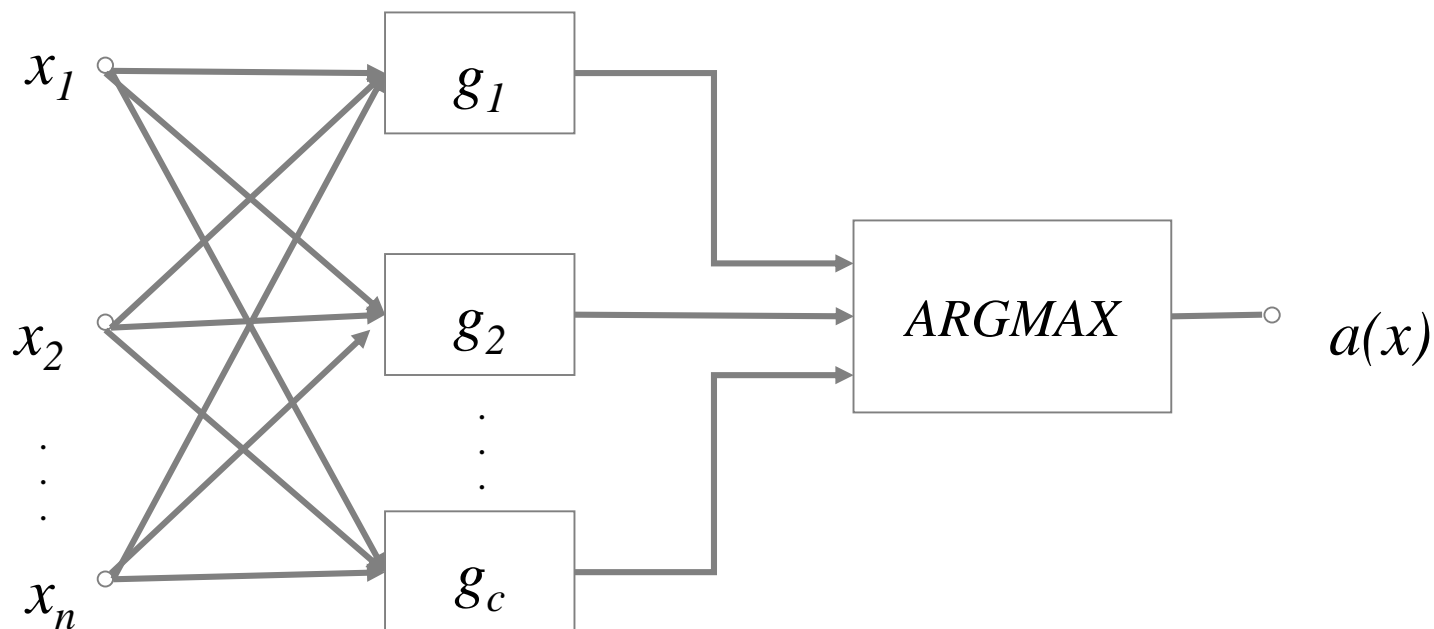
$$g_i(x) = g_j(x)$$



2.2.4 分类器设计

◆ 分类器是某种由硬件或软件组成的“机器”：

- 计算 c 个判别函数 $g_i(\mathbf{x})$
- 最大值选择



2.2.4 分类器设计

两类情况

决策规则

$$\text{if } g(x) = g_1(x) - g_2(x) \begin{matrix} > \\ < \end{matrix} 0 \text{ then } x \in \begin{matrix} \omega_1 \\ \omega_2 \end{matrix}$$

判别函数（仅定义一个）

$$g(x) = P(\omega_1 | x) - P(\omega_2 | x)$$


$$g(x) = p(x | \omega_1)P(\omega_1) - p(x | \omega_2)P(\omega_2)$$

$$g(x) = \ln \frac{p(x | \omega_1)}{p(x | \omega_2)} - \ln \frac{P(\omega_1)}{P(\omega_2)}$$

决策面方程

$$g(x) = 0$$

- x 为一维时，决策面为一点
- x 为二维时决策面为曲线
- x 为三维时，决策面为曲面
- x 大于三维时决策面为超曲面



2.2.4 分类器设计

例2.1、2.2的判别函数和决策面

2.1

判别函数
$$g(x) = p(x | \omega_1)P(\omega_1) - p(x | \omega_2)P(\omega_2)$$
$$= 0.9p(x | \omega_1) - 0.1p(x | \omega_2)$$

决策面方程
$$9p(x | \omega_1) - p(x | \omega_2) = 0$$

2.2

判别函数
$$g(x) = \lambda_{21}p(x | \omega_1)P(\omega_1) - \lambda_{12}p(x | \omega_2)P(\omega_2)$$
$$= 0.9p(x | \omega_1) - 0.6p(x | \omega_2) \quad [\lambda_{21} = 1, \lambda_{12} = 6]$$

决策面方程
$$9p(x | \omega_1) - 6p(x | \omega_2) = 0$$

2.3 正态分布时的统计决策

- **Bayes**决策的三个前提：
 - 类别数确定
 - 各类的先验概率 $P(\omega_i)$ 已知
 - 各类的条件概率密度函数 $p(x|\omega_i)$ 已知
- **Bayes**决策中，类条件概率密度的选择要求：
 - 模型合理性
 - 计算可行性
- **最常用概率密度模型：正态分布**
 - 观测值通常是很多种因素共同作用的结果，根据中心极限定理，它们（近似）服从正态分布
 - 计算、分析最为简单的模型

2.3.1 关于正态分布的知识

单变量正态分布（一元正态分布）

- 概率密度函数


$$p(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

- 两个重要参数

- 均值（中心）
- 方差（分散度）

$$\mu = E\{x\} = \int_{-\infty}^{\infty} xp(x)dx$$

$$\sigma^2 = E\{(x-\mu)^2\} = \int_{-\infty}^{\infty} (x-\mu)^2 p(x)dx$$



2.3.1 关于正态分布的知识

- 多元正态分布
 - 概率密度函数

$$p(\mathbf{x}) = \frac{1}{(2\pi)^{d/2} |\Sigma|^{1/2}} \exp(-\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu})^T \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu}))$$


$$\mathbf{x} = (x_1, x_2, \dots, x_d)^T$$

均值向量 $\boldsymbol{\mu} = E(\mathbf{x}) = (\mu_1, \mu_2, \dots, \mu_d)^T, \mu_i = E(x_i)$

协方差矩阵 $\Sigma = E\{(\mathbf{x} - \boldsymbol{\mu})(\mathbf{x} - \boldsymbol{\mu})^T\} = (\sigma_{ij}^2)_{d \times d}$

$$\sigma_{ij}^2 = E[(x_i - \mu_i)(x_j - \mu_j)]$$

协方差矩阵是对称矩阵



2.3.1 关于正态分布的知识

多元正态分布的性质

- 参数 μ 和 Σ 完全决定分布


$$p(\mathbf{x}) \sim N(\mu, \Sigma)$$

- 等概率密度轨迹为超椭球面
 - Mahalanobis距离（马氏距离）

$$p(\mathbf{x}) = c \Rightarrow (\mathbf{x} - \mu)^T \Sigma^{-1} (\mathbf{x} - \mu) = \gamma^2$$

- 不相关性等价于独立性
- 边缘分布和条件分布的正态性
- 线性变换的正态性 $\mathbf{y} = A\mathbf{x}$
- 线性组合的正态性 $y = \alpha^T \mathbf{x}$

（一维）



2.3.2 正态分布下的贝叶斯决策

最小错误率贝叶斯判别函数和决策面

- 观测向量的类条件分布服从正态分布:

$$p(\mathbf{x} | \omega_i) \propto N(\boldsymbol{\mu}_i, \Sigma_i), \quad i = 1, 2, \dots, c$$

- 判别函数

$$g_i(\mathbf{x}) = \ln p(\mathbf{x} | \omega_i) + \ln P(\omega_i)$$

- 决策面方程

$$g_i(x) = g_j(x)$$

2.3.2 正态分布下的贝叶斯决策

- 1. 第一种情况：等协方差阵，独立，且同方差

$$\Sigma_i = \sigma^2 I = \begin{bmatrix} \sigma_{11}^2 & \dots & 0 \\ \dots & \dots & \dots \\ 0 & \dots & \sigma_{nn}^2 \end{bmatrix}, \quad i = 1, 2, \dots, c$$

- 判别函数简化为

$$g_i(\mathbf{x}) = -\frac{1}{2\sigma^2} (\mathbf{x} - \boldsymbol{\mu}_i)^T (\mathbf{x} - \boldsymbol{\mu}_i) + \ln P(\omega_i)$$

$$(\mathbf{x} - \boldsymbol{\mu}_i)^T (\mathbf{x} - \boldsymbol{\mu}_i) = \|\mathbf{x} - \boldsymbol{\mu}_i\|^2 = \sum_{j=1}^d (x_j - \mu_{ij})^2$$

欧氏距离

2.3.2 正态分布下的贝叶斯决策


- 1. 第一种情况：等协方差阵，独立，且同方差
 - 特例：先验概率相等

$$\Sigma_i = \sigma^2 I, \quad P(\omega_i) = P(\omega_j) \quad i, j = 1, 2, \dots, c$$

$$g_i(\mathbf{x}) = -\frac{1}{2\sigma^2} (\mathbf{x} - \boldsymbol{\mu}_i)^T (\mathbf{x} - \boldsymbol{\mu}_i) = -\frac{1}{2\sigma^2} \|\mathbf{x} - \boldsymbol{\mu}_i\|^2$$

$$j = \arg \min_{i=1, \dots, c} \|\mathbf{x} - \boldsymbol{\mu}_i\|^2$$

最小距离分类器
(模板匹配)



2.3.2 正态分布下的贝叶斯决策

- 1. 第一种情况：等协方差阵，独立，且同方差
 - 考虑二次项 $\mathbf{x}^T \mathbf{x}$ 与 i 无关

$$g_i(\mathbf{x}) = -\frac{1}{2\sigma^2} (-2\boldsymbol{\mu}_i^T \mathbf{x} + \boldsymbol{\mu}_i^T \boldsymbol{\mu}_i) + \ln P(\omega_i) = \mathbf{w}_i^T \mathbf{x} + w_{i0},$$

$$\text{其中: } \mathbf{w}_i = \frac{1}{\sigma^2} \boldsymbol{\mu}_i, w_{i0} = -\frac{1}{2\sigma^2} \boldsymbol{\mu}_i^T \boldsymbol{\mu}_i + \ln P(\omega_i)$$

$$j = \arg \max_{i=1, \dots, c} g_i(\mathbf{x})$$

线性分类器

2.3.2 正态分布下的贝叶斯决策

- 决策面方程（线性）

$$g_i(\mathbf{x}) - g_j(\mathbf{x}) = 0$$



- 改写为

$$\mathbf{w}^T (\mathbf{x} - \mathbf{x}_0) = 0$$

其中 $\mathbf{w} = \boldsymbol{\mu}_i - \boldsymbol{\mu}_j$

$$\mathbf{x}_0 = \frac{1}{2}(\boldsymbol{\mu}_i + \boldsymbol{\mu}_j) - \frac{\sigma^2 (\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)}{\|\boldsymbol{\mu}_i - \boldsymbol{\mu}_j\|^2} \ln \frac{P(\omega_i)}{P(\omega_j)}$$

- 决策面为一超平面，



2.3.2 正态分布下的贝叶斯决策

2. 第二种情况：等协方差阵

$$\Sigma_i = \Sigma, \quad i = 1, 2, \dots, c$$

- 判别函数简化为

$$g_i(\mathbf{x}) = -\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_i)^T \Sigma^{-1}(\mathbf{x} - \boldsymbol{\mu}_i) + \ln P(\omega_i)$$

$$P(\omega_i) = P(\omega_j) \quad \text{时}$$

$$g_i(\mathbf{x}) = \gamma^2 = (\mathbf{x} - \boldsymbol{\mu}_i)^T \Sigma^{-1}(\mathbf{x} - \boldsymbol{\mu}_i)$$

马氏距离

2.3.2 正态分布下的贝叶斯决策

2. 第二种情况：等协方差阵

- 线性判别函数

$$g_i(\mathbf{x}) = \mathbf{w}_i^T \mathbf{x} + w_{i0}$$

$$\mathbf{w}_i = \Sigma^{-1} \boldsymbol{\mu}_i,$$


$$w_{i0} = -\frac{1}{2} \boldsymbol{\mu}_i^T \Sigma^{-1} \boldsymbol{\mu}_i + \ln P(\omega_i)$$

- 决策面方程

$$\mathbf{w}^T (\mathbf{x} - \mathbf{x}_0) = 0$$

$$\mathbf{w} = \Sigma^{-1} (\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)$$

$$\mathbf{x}_0 = \frac{1}{2} (\boldsymbol{\mu}_i + \boldsymbol{\mu}_j)$$



2.3.2 正态分布下的贝叶斯决策

3. 第三种情况：各类协方差阵不相等

$$\Sigma_i \neq \Sigma_j, \quad i, j = 1, 2, \dots, c$$

- 判别函数为


$$\begin{aligned} g_i(\mathbf{x}) &= -\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_i)^T \Sigma_i^{-1}(\mathbf{x} - \boldsymbol{\mu}_i) - \frac{1}{2} \ln |\Sigma_i| + \ln P(\omega_i) \\ &= \mathbf{x}^T \mathbf{W}_i \mathbf{x} + \mathbf{w}_i^T \mathbf{x} + w_{i0} \end{aligned}$$

- 为二次型，决策面为超二次曲面


$$\mathbf{x}^T (\mathbf{W}_i - \mathbf{W}_j) \mathbf{x} + (\mathbf{w}_i - \mathbf{w}_j)^T \mathbf{x} + w_{i0} - w_{j0} = 0$$

2.3.2 正态分布下的贝叶斯决策


- 两类决策面（超二次曲面）




(a)圆




(b)椭圆



(c)抛物线



(d)双曲线



(e)直线

2.3.2 正态分布下的贝叶斯决策

- 例2.3 两类的识别问题：医生要根据病人血液中白细胞的浓度来判断病人是否患血液病
 - 根据医学知识和以往的经验，医生知道：
 - 患病的人，白细胞的浓度服从均值2000，标准差1000的正态分布；未患病的人，白细胞的浓度服从均值7000，标准差3000的正态分布；
 - 一般人群中，患病的人数比例为0.5%。
 - 一个人的白细胞浓度是3100
 - 医生应该做出怎样的判断？

2.3.2 正态分布下的贝叶斯决策

- 用 ω 表示“类别”这一随机变量， ω_1 表示患病， ω_2 表示正常； x 表示“白细胞浓度”这个随机变量

1) 类别的先验分布：

$$P(\omega_1) = 0.5\%$$

$$P(\omega_2) = 99.5\%$$

2) 观测数据白细胞浓度分别在两种情况下的类条件分布：

$$P(x|\omega_1) \sim N(2000, 1000^2)$$

$$P(x|\omega_2) \sim N(7000, 3000^2)$$

$$P(3100|\omega_1) = 2.1785\text{e-}004$$

$$P(3100|\omega_2) = 5.7123\text{e-}005$$

3) 计算后验概率

$$P(\omega_1|3100) = 1.9\% \quad P(\omega_2|3100) = 98.1\%$$

◆ 医生的判断：正常



2.4 关于分类器的错误率问题

研究错误的意义

- 对于同一规则，错误率反映问题的固有复杂程度（bayes 问题）
- 对于同一问题，错误率反映不同方法的优劣

错误率计算

$$\begin{aligned} P(e) &= P(\omega_1) \int_{R_2} p(x | \omega_1) dx + P(\omega_2) \int_{R_1} p(x | \omega_2) dx \\ &= P(\omega_1) P_1(e) + P(\omega_2) P_2(e) \end{aligned}$$

- 1) 按理论公式计算
- 2) 计算错误率上界
- 3) 实验估计：C法、交叉验证（划分、留一）

2.5 讨论

- 基于**Bayes**决策的最优分类器
 - 最优的条件
 - 评价指标（错误率、风险）

$$P(\omega_i | \mathbf{x}) = \frac{p(\mathbf{x} | \omega_i)P(\omega_i)}{\sum_j p(\mathbf{x} | \omega_j)P(\omega_j)}$$

Bayes决策的三个前提：

- 1) 类别数确定
- 2) 各类的先验概率 $P(\omega_i)$ 已知
- 3) 各类的条件概率密度函数 $p(\mathbf{x}|\omega_i)$ 已知

基于样本估计概率密度

基于样本直接确定判别函数
(直接设计分类器)

正态分布的Bayes决策例解

- ◆ 两类的识别问题：医生要根据病人血液中白细胞的浓度来判断病人是否患血液病。
- ◆ 根据医学知识和以往的经验，医生知道：
 - 患病的人，白细胞的浓度服从均值2000，标准差1000的正态分布；未患病的人，白细胞的浓度服从均值7000，标准差3000的正态分布；
 - 一般人群中，患病的人数比例为0.5%。
 - 一个人的白细胞浓度是3100，医生应该做出怎样的判断？

正态分布的Bayes决策例解

◆ 数学表示:

- 用 ω 表示“类别”这一随机变量， ω_1 表示患病， ω_2 表示正常；
- x 表示“白细胞浓度”这个随机变量。

◆ 本例医生掌握的知识非常充分，包括:

- 1) 类别的先验分布: $P(\omega_1) = 0.5\%$, $P(\omega_2) = 99.5\%$

先验分布: 没有获得观测数据（病人白细胞浓度）之前，已知的关于类别的分布（某类事物出现的比例）。

正态分布的Bayes决策例解

2) 观测数据白细胞浓度分别在两种情况下的类条件分布:

$$P(x|\omega_1) \sim N(2000, 1000^2)$$

$$P(x|\omega_2) \sim N(7000, 3000^2)$$

◆ 样本观测值: $x = 3100$

$$P(3100|\omega_1) = 2.1785e-004, P(3100|\omega_2) = 5.7123e-005$$

◆ 计算后验概率:

$$P(\omega_1|3100) = 1.9\%, P(\omega_2|3100) = 98.1\%$$

◆ 医生的判断: 正常

习题

1. 对一个 c 类分类问题，假设各类先验概率为 $P(\omega_i), i=1, \dots, c$ ，条件概率密度为

$P(\mathbf{x} | \omega_i), i=1, \dots, c$ （这里 \mathbf{x} 表示特征向量），将第 j 类模式判别为第 i 类的损失为 λ_{ij} 。

(1) 请写出贝叶斯最小风险决策和最小错误率决策的决策规则；

(2) 引入拒识（表示为第 $c+1$ 类），假设决策损失为

$$\lambda_{ij} = \begin{cases} 0, & i = j \\ \lambda_r, & i = c+1 \\ \lambda_s, & \text{otherwise} \end{cases}$$

请写出最小损失决策的决策规则（包括分类规则和拒识规则）。



2. 表示模式的特征向量 $\mathbf{x} \in R^d$ ，对一个 c 类分类问题，假设各类先验概率相等，每一类条件概率密度为高斯分布。

(1) 请写出类条件概率密度函数的数学形式；

(2) 请写出在下面两种情况下的最小错误率决策判别函数：(a)类协方差矩阵不等；(b)所有类协方差矩阵相等。

- 3 设 $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N$ 是来源于已知协方差矩阵、未知均值的正态分布的向量，即

$$p(\mathbf{x}_k; \boldsymbol{\mu}) = \frac{1}{(2\pi)^{d/2} |\Sigma|^{1/2}} \exp\left(-\frac{1}{2}(\mathbf{x}_k - \boldsymbol{\mu})^T \Sigma^{-1}(\mathbf{x}_k - \boldsymbol{\mu})\right)$$

求出未知均值向量的最大似然估计。

假设在上例中的未知均值向量 $\boldsymbol{\mu}$ 现在是已知的，且服从的正态分布是

$$p(\boldsymbol{\mu}) = \frac{1}{(2\pi)^{d/2} \sigma_{\boldsymbol{\mu}}^2} \exp\left(-\frac{1}{2} \frac{\|\boldsymbol{\mu} - \boldsymbol{\mu}_0\|^2}{\sigma_{\boldsymbol{\mu}}^2}\right)$$

通过下式得到最大后验概率估计：

$$\frac{\partial}{\partial \boldsymbol{\mu}} \ln \left(\prod_{k=1}^N p(\mathbf{x}_k | \boldsymbol{\mu}) p(\boldsymbol{\mu}) \right) = 0$$

每位同学严格命名

学号_姓名

作业缴交地址：

<ftp://210.34.246.224/>

210.34.246.224 ▶ 作业缴交 ▶ 计算机学院_柳欣 ▶ 研究生模式识别课程 ▶ 作业1

工具(T) 帮助(H)

