



# 第三章

# 概率密度函数的估计

任课教师：柳欣老师

email: [starxliu@163.com](mailto:starxliu@163.com)

# 模式识别案例库小组任务

## 【案例库名称】

## 【案例描述】

该部分详细描述案例的背景、应用场景、面临的问题，以及案例可行性分析

## 【案例实现过程描述】

该部分详细描述案例实现的技术方案，包括但不限于实现的模型，框架，技术路线，步骤、算法描述等。

## 【案例结果展示】

该部分主要显示案例库实现的结果，包括结果图、表以及相应的介绍。

## 【提交的资料】

提交资料：案例库文档，源代码，开发环境、代码使用说明，运行截图；案例库介绍PPT（用于汇报）；



采集比对主界面

### 产品性能

测试的硬件环境是：CPU 主频 2.33GHz，内存 4G

目标库容：1000 人；目标库来源：员工照片

规格项	描述
最小人脸尺寸	60×60 px
人脸特征大小	5K Byte
人脸检测速度	10ms
眼睛定位速度	22ms
特征提取速度	98ms
比对速度	30 万次/秒
比对性能	正确识别率：85.2% 错误识别率：0.55% 错误拒绝率：14.7%
报警时间	小于 3 秒钟





## 3.1 引言

### 主要估计方法

#### ○ 参数估计

- 先假定研究问题具有某种数学模型，如正态分布，二项分布，再用已知类别的学习样本估计里面的参数（**最大似然估计**，**bayes估计**）

#### ○ 非参数估计

- 不假定数学模型，直接用已知类别的学习样本先验知识估计数学模型。（**Parzen窗法**和**Kn-近邻方法**）

## 3.1 引言

### ○ 分类器设计

- ◆ 贝叶斯决策需要已知两种知识：
  - 各类的先验概率 $P(\omega_i)$
  - 各类的条件概率密度函数 $p(\mathbf{x}|\omega_i)$
- ◆ 实际问题
  - 已知有限数目样本



对未知  
样本分类

### ○ 基于样本的两步贝叶斯决策

- 利用样本集估计 $P(\omega_i)$ 和 $p(\mathbf{x}|\omega_i)$ , 记  $\hat{p}(\mathbf{x}|\omega_i)$  和  $\hat{P}(\omega_i)$
- 基于上述估计值设计贝叶斯分类器
- 希望: 当样本数 $N \rightarrow \infty$ 时, 如此得到的分类器能收敛于理论上的最优解



## 3.1 引言

### ○ 本章问题

- 如何利用样本集估计
- 估计量的性质如何：收敛；无偏性、有效性、一致性
- 利用样本集估计错误率的方法

#### ◆ 类的**先验概率** $P(\omega_i)$ 的估计：

- 用训练数据中各类出现的频率来估计
- 依靠经验

#### ◆ 类条件**概率密度函数**的估计：两大类方法

- **参数估计**：概率密度函数的形式已知，而表征函数的参数未知，需要通过训练数据来估计
  - 矩估计、最大似然估计、Bayes估计
- **非参数估计**：概率密度函数的形式未知，也不作假设，利用训练数据直接对概率密度进行估计
  - Parzen窗法和 $k_n$ -近邻法

## 3.2 参数估计

### 参数估计的基本概念

- 统计量：样本集 $\mathbf{X}=\{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N\}$ 的某种函数 $d(\mathbf{X})$
  - 参数空间：总体分布的未知参数 $\theta$ 所有可能取值组成的集合  $\Theta$
  - 点估计、估计量和估计值：
    - 点估计：构造一个统计量 $d(\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N)$ 作为参数 $\theta$ 的估计
- $\theta$ 的估计量 $\hat{\theta} = d(\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N)$ 是样本集的函数  
它对样本集的一次实现称为估计值
- 区间估计：求参数的置信区间

## 3.2 参数估计

### ○ 估计量的评价标准:

- **无偏性**: 估计量的数学期望  $E(\hat{\theta}) = \theta$

渐进无偏: 当样本数趋于无穷时估计才具有无偏性

$$\lim_{N \rightarrow \infty} (E(\hat{\theta}) - \theta) = 0$$

- **一致性**: 对任意 $\varepsilon$ 样本数趋于无穷时, 依概率趋于 $\theta$ :

$$\lim_{N \rightarrow \infty} P(|\hat{\theta} - \theta| > \varepsilon) = 0$$

◆ 无偏性、有效性都只是说明对于多次估计来说, 估计量能以较小的方差平均地表示其真实值, 并不能保证具体的一次估计的性能; 而一致性则保证当样本数无穷多时, 每次的估计量都将在概率意义上任意地接近其真实值

## 3.2.1 最大似然估计

### 假设

- (1) 估计的**参数 $\theta$ 是确定而未知的**，而Bayes估计方法则视 $\theta$ 为随机变量
- (2) 样本集可按类别分开，样本集 $\mathbf{x}_i$ 中的样本都是从概率密度为 $p(\mathbf{x}|\omega_i)$ 的总体中独立抽取出来的(i.i.d条件)
- (3)  $p(\mathbf{x}|\omega_i)$  具有某种确定的函数形式，只是其参数 $\theta_i$ 未知。为表示 $p(\mathbf{x}|\omega_i)$ 同 $\theta_i$ 有关，记作 $p(\mathbf{x}|\omega_i, \theta_i)$
- (4) 各类样本只包含本类分布信息，不同类别的参数是独立的，这样就可以分别对每一类进行处理

### 每个类别都用相同的方法，表示类别的下标可以省略



## 3.2.1 最大似然估计

### 问题描述

- 独立地按概率密度 $p(\mathbf{x}|\boldsymbol{\theta})$ 抽取样本集 $\mathbf{X}=\{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N\}$ , 用 $\mathbf{X}$ 估计未知参数 $\boldsymbol{\theta}$

### 似然函数 (likelihood function)

- 相对于样本集的 $\boldsymbol{\theta}$ 的函数, 是 $N$ 个随机变量的联合密度

$$l(\boldsymbol{\theta}) = p(\mathbf{X} | \boldsymbol{\theta}) = p(\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N | \boldsymbol{\theta}) = \prod_{k=1}^N p(\mathbf{x}_k | \boldsymbol{\theta})$$

### 最大似然估计量


- 使似然函数极大化

$$\hat{\boldsymbol{\theta}} = d(\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N) = \operatorname{argmax}_{\boldsymbol{\theta}} l(\boldsymbol{\theta})$$

- 直观理解: 参数 $\boldsymbol{\theta}$ 的最大似然估计就是最符合给定的观测样本集的那一个

## 3.2.1 最大似然估计

### 一维正态分布示例



- 注意似然函数 $p(\mathbf{X}|\theta)$ 和条件概率密度函数 $p(\mathbf{x}|\theta)$ 的区别：  
前者是 $\theta$ 的函数，并不表示概率密度，后者是以 $\theta$ 为参数的关于 $\mathbf{x}$ 的函数

## 3.2.1 最大似然估计

### 最大似然估计量的求解

$$\hat{\boldsymbol{\theta}}_{ML} = \underset{\boldsymbol{\theta}}{\operatorname{argmax}} l(\boldsymbol{\theta})$$

- $\theta$  为标量，似然函数连续可微，最大似然估计量为微分方程的解

$$\frac{dl(\theta)}{d\theta} = 0$$

- 取似然函数的对数

$$H(\theta) = \ln l(\theta) = \sum_{k=1}^n \ln p(\mathbf{x}_k | \theta)$$

$$\frac{dH(\theta)}{d\theta} = 0$$

## 3.2.1 最大似然估计

- 当 $\theta$ 为有 $S$ 个分量的未知向量

$$\boldsymbol{\theta} = [\theta_1, \theta_2, \dots, \theta_S]$$


- 记梯度算子

$$\nabla_{\boldsymbol{\theta}} = \left[ \frac{\partial}{\partial \theta_1}, \frac{\partial}{\partial \theta_2}, \dots, \frac{\partial}{\partial \theta_S} \right]^T$$

- 最大似然估计的必要条件

$$\nabla_{\boldsymbol{\theta}} H(\boldsymbol{\theta}) \big|_{\hat{\boldsymbol{\theta}}_{ML}} = \sum_{k=1}^N \nabla_{\boldsymbol{\theta}} \ln p(\mathbf{x}_k | \boldsymbol{\theta}) \big|_{\hat{\boldsymbol{\theta}}_{ML}} = 0$$

- 如必要条件有多解，需从中求使似然函数最大者
- 若不满足连续可导，则无一般性方法，用其它方法求最大



## 3.2.1 最大似然估计

### 正态分布的最大似然估计

(1)  $\mu$ 未知,  $\Sigma$ 已知的情况

- $p(x|\theta)$ 服从正态分布, 待估参数为 $\theta = \mu$

$$\ln p(x_k | \mu) = -\frac{1}{2} \ln \left[ (2\pi)^d |\Sigma| \right] - \frac{1}{2} (x_k - \mu)^t \Sigma^{-1} (x_k - \mu)$$

$$\nabla_{\mu} \ln p(x_k | \mu) = \Sigma^{-1} (x_k - \mu)$$

$$\nabla_{\theta} H(\theta) = \sum_{k=1}^{k=n} \Sigma^{-1} (x_k - \hat{\mu}) = 0 \Rightarrow \hat{\mu} = \frac{1}{n} \sum_{k=1}^{k=n} x_k$$

- 即均值的最大似然估计等于样本均值

## 3.2.1 最大似然估计

(2)  $\mu$  和  $\Sigma$  均未知的情况

$$p(x_k | \theta_1 = \mu, \theta_2 = \sigma^2) = \frac{1}{\sqrt{2\pi\theta_2}} \exp\left(-\frac{(x_k - \theta_1)^2}{2\theta_2}\right)$$

$$\ln p(x_k | \theta_1, \theta_2) = -\frac{1}{2} \ln(2\pi\theta_2) - \frac{1}{2\theta_2} (x_k - \theta_1)^2$$

$$\nabla_{\theta} H(\theta) |_{\hat{\theta}_{ML}} = \sum_{k=1}^N \nabla_{\theta} \ln p(x_k | \theta) |_{\hat{\theta}_{ML}} = 0$$

$$\left. \begin{aligned} \frac{\partial}{\partial \theta_1} \ln p(x_k | \theta_1, \theta_2) &= \frac{1}{\theta_2} (x_k - \theta_1) \\ \frac{\partial}{\partial \theta_2} \ln p(x_k | \theta_1, \theta_2) &= -\frac{1}{2\theta_2} + \frac{(x_k - \theta_1)^2}{2\theta_2^2} \end{aligned} \right\} \Rightarrow \left\{ \begin{aligned} \hat{\mu} &= \frac{1}{N} \sum_{k=1}^N x_k \\ \hat{\sigma}^2 &= \frac{1}{N} \sum_{k=1}^N (x_k - \hat{\mu})^2 \end{aligned} \right.$$

## 3.2.1 最大似然估计

- 多元正态分布参数最大似然估计

$$\hat{\boldsymbol{\mu}} = \frac{1}{N} \sum_{k=1}^N \mathbf{x}_k \quad \hat{\boldsymbol{\Sigma}} = \frac{1}{N} \sum_{k=1}^N (\mathbf{x}_k - \hat{\boldsymbol{\mu}})(\mathbf{x}_k - \hat{\boldsymbol{\mu}})^T$$

- ◆ 最大似然估计是一致估计
- ◆ 均值估计是无偏的，协方差矩阵估计是有偏的。
- ◆ 协方差矩阵的无偏估计是：

如果一个变量的期望等于他的理想值，那么就称该变量无偏；否则称为有偏。  
无偏估计的要求就是：估计出来的参数的数学期望等于被估计参数的真实值。

$$\hat{\boldsymbol{\Sigma}} = \frac{1}{N-1} \sum_{k=1}^N (\mathbf{x}_k - \hat{\boldsymbol{\mu}})(\mathbf{x}_k - \hat{\boldsymbol{\mu}})^T \quad \text{课后习题}$$

均值估计是无偏的，方差估计是有偏的





$$p_i = P(X = x_i) \quad (1.1)$$

$$E(X) = \sum_{i=1}^n x_i p_i \quad (1.2)$$

$$D(X) = E\left(\left(X - E(X)\right)^2\right) = \sum_{i=1}^n \left(x_i - E(X)\right)^2 p_i \quad (1.3)$$

*D(x)为样本的总体方差*

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \quad (1.4)$$

$$E(\bar{X}) = \frac{1}{n} E\left(\sum_{i=1}^n X_i\right) = \frac{1}{n} \sum_{i=1}^n E(X_i) = \mu \quad (1.5)$$

$$D(\bar{X}) = \frac{1}{n^2} D\left(\sum_{i=1}^n X_i\right) = \frac{1}{n^2} \sum_{i=1}^n D(X_i) = \frac{\sigma^2}{n} \quad (1.6)$$

Sample Variance is defined as equation(1.7):

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 \quad (1.7)$$





The unbiasedness of Sample Mean and Sample Variance is as follows:

$$\begin{cases} E(\bar{X}) = E(X) \\ E(S^2) = D(X) \end{cases} \quad (1.8)$$

$$\begin{aligned} D(X) &= E(X^2) - (E(X))^2 & E(X_i) &= E(\bar{X}) = \mu \\ E(X^2) &= D(X) + (E(X))^2 & D(X_i) &= \sigma^2, D(\bar{X}) = \frac{\sigma^2}{n} \end{aligned}$$

$$\begin{aligned} E(X_i^2) &= D(X_i) + \mu^2 = \sigma^2 + \mu^2 & E(S^2) &= \frac{1}{n-1} E\left(\sum_{i=1}^n (X_i - \bar{X})^2\right) \\ E(\bar{X}^2) &= D(\bar{X}) + \mu^2 = \frac{\sigma^2}{n} + \mu^2 & &= \frac{1}{n-1} E\left(\sum_{i=1}^n (X_i^2 - 2\bar{X}X_i + \bar{X}^2)\right) \\ E(\bar{X}X_i) &= E\left(\frac{X_1X_i + X_2X_i + \cdots + X_i^2 + \cdots + X_nX_i}{n}\right) & &= \frac{1}{n-1} \sum_{i=1}^n \left(E(X_i^2 - 2\bar{X}X_i + \bar{X}^2)\right) \\ &= \frac{1}{n} \left(\sum_{\substack{k=0 \\ k \neq i}}^n E(X_kX_i) + E(X_i^2)\right) & &= \frac{1}{n-1} \left(2n\mu^2 + (n+1)\sigma^2 - 2\sum_{i=1}^n (E(\bar{X}X_i))\right) \\ &= \frac{1}{n} ((n-1)\mu^2 + (\sigma^2 + \mu^2)) & &= \frac{1}{n-1} \left(2n\mu^2 + (n+1)\sigma^2 - 2n\left(\frac{\sigma^2}{n} + \mu^2\right)\right) \\ &= \frac{\sigma^2}{n} + \mu^2 & &= \sigma^2 \\ &= E(\bar{X}^2) & &= D(X) \end{aligned}$$

当两个变量不相关时正确，乘积的期望等于期望的乘积



## 3.2.2 贝叶斯估计和贝叶斯学习

- 最大后验概率估计-**Maximum a posteriori (MAP)**
  - 用一组样本集 $\mathbf{X} = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N\}$ 估计未知参数  $\theta$
  - 未知参数  $\theta$  视为随机变量, 先验分布为  $p(\theta)$ , 而在已知样本集 $\mathbf{X}$ 出现的条件下的后验概率为  $p(\theta | \mathbf{X})$

$$\begin{aligned}\hat{\theta}_{\text{MAP}} &= \operatorname{argmax}_{\theta} p(\theta | \mathbf{X}) \\ &= \operatorname{argmax}_{\theta} \frac{p(\mathbf{X} | \theta) p(\theta)}{p(\mathbf{X})} \\ &= \operatorname{argmax}_{\theta} p(\mathbf{X} | \theta) p(\theta)\end{aligned}$$

## 3.2.2 贝叶斯估计和贝叶斯学习

### 贝叶斯决策问题与贝叶斯估计问题

#### ◆ 贝叶斯决策问题:

样本  $\mathbf{x}$

决策  $a_i$

真实状态  $\omega_j$

状态空间  $\mathcal{A}$  是离散空间

先验概率  $P(\omega_j)$

#### ◆ 贝叶斯参数估计问题:

样本集  $\mathbf{X}$

估计量  $\hat{\theta}$

真实参数  $\theta$

参数空间  $\Theta$  是连续空间

参数的先验分布  $p(\theta)$

## 3.2.2 贝叶斯估计和贝叶斯学习

- 参数估计的条件风险：给定 $\mathbf{x}$ 条件下，估计量的期望损失

$$R(\hat{\theta} | \mathbf{x}) = \int_{\Theta} \lambda(\hat{\theta}, \theta) p(\theta | \mathbf{x}) d\theta$$

- 参数估计的贝叶斯风险：估计量的条件风险的期望

$$R = \int_{E^d} R(\hat{\theta} | \mathbf{x}) p(\mathbf{x}) d\mathbf{x}$$

- 贝叶斯估计：使风险最小的估计

$$\hat{\theta}_{\text{BE}} = \operatorname{argmax}_{\hat{\theta}} R(\hat{\theta} | \mathbf{x})$$

## 3.2.2 贝叶斯估计和贝叶斯学习

- 损失函数定义为误差平方:

$$\lambda(\hat{\theta}, \theta) = (\theta - \hat{\theta})^2$$

$$\lambda(\hat{\theta}, \theta) = |\theta - \hat{\theta}|$$

绝对误差损失函数

$$\begin{aligned} R(\hat{\theta} | \mathbf{x}) &= \int_{\Theta} \lambda(\hat{\theta}, \theta) p(\theta | \mathbf{x}) d\theta \\ &= \int_{\Theta} [\theta - E(\theta | \mathbf{x})]^2 p(\theta | \mathbf{x}) d\theta + \\ &\quad \int_{\Theta} [E(\theta | \mathbf{x}) - \hat{\theta}]^2 p(\theta | \mathbf{x}) d\theta \end{aligned}$$

- 定理 3.1:** 如果定义损失函数为误差平方函数, 则有:

$$\hat{\theta}_{\text{BE}} = E[\theta | \mathbf{x}] = \int_{\Theta} \theta p(\theta | \mathbf{x}) d\theta$$

## 3.2.2 贝叶斯估计和贝叶斯学习

### 贝叶斯估计的步骤

1. 确定 $\theta$ 的先验分布  $p(\theta)$
2. 由样本集 $\mathbf{X} = \{x_1, x_2, \dots, x_N\}$ 求出样本联合分布:  $p(\mathbf{X} | \theta)$
3. 计算 $\theta$ 的后验分布

$$p(\theta | X) = \frac{p(X | \theta) p(\theta)}{\int_{\Theta} p(X | \theta) p(\theta) d\theta}$$

4. 计算贝叶斯估计

$$\hat{\theta}_{\text{BE}} = \int_{\Theta} \theta p(\theta | X) d\theta$$

## 3.2.2 贝叶斯估计和贝叶斯学习

### ○ 贝叶斯学习

- 利用 $\theta$ 的先验分布  $p(\theta)$  及样本提供的信息求出 $\theta$ 的后验分布  $p(\theta | \mathbf{X})$ ，然后直接求总体分布  $p(\mathbf{x} | \mathbf{X})$

$$p(\mathbf{x} | \mathbf{X}) = \int p(\mathbf{x}, \theta | \mathbf{X}) d\theta = \int p(\mathbf{x} | \theta) p(\theta | \mathbf{X}) d\theta$$

- 递推贝叶斯方法—学习(收敛于真实参数为中心的 $\delta$ 函数)


$$\mathbf{X}^N = \{x_1, x_2, \dots, x_N\}$$

$$p(\mathbf{X}^N | \theta) = p(x_N | \theta) p(\mathbf{X}^{N-1} | \theta)$$

$$p(\theta | \mathbf{X}^N) = \frac{p(x_N | \theta) p(\mathbf{X}^{N-1} | \theta)}{\int p(x_N | \theta) p(\mathbf{X}^{N-1} | \theta) d\theta}$$

## 3.2.2 贝叶斯估计和贝叶斯学习

### ○ 正态分布的贝叶斯学习过程





## 3.2.2 贝叶斯估计和贝叶斯学习

### ○ 正态分布的贝叶斯估计

- 单变量,  $\mu$ 未知,  $\sigma^2$ 已知的情况

- 总体分布密度为  $p(x|\mu) \sim N(\mu, \sigma^2)$

- $\mu$ 的先验分布为  $p(\mu) \sim N(\mu_0, \sigma_0^2)$

- 后验分布 
$$p(\theta|X) = \frac{p(X|\theta)p(\theta)}{\int_{\Theta} p(X|\theta)p(\theta)d\theta}$$

- 贝叶斯估计方法求 $\mu$ 的估计量

$$\hat{\mu}_{\text{BE}} = \int_{\Theta} \mu p(\mu|X) d\mu$$

## 3.2.2 贝叶斯估计和贝叶斯学习

- 后验概率

$$p(\mu | X) = \frac{p(X | \mu) p(\mu)}{p(X)}$$

$$= \alpha \prod_{k=1}^N p(x_k | \mu) p(\mu) \sim N(\mu_N, \sigma_N^2)$$

$$\mu_N = \frac{N\sigma_0^2}{N\sigma_0^2 + \sigma^2} m_N + \frac{\sigma^2}{N\sigma_0^2 + \sigma^2} \mu_0 \quad \sigma_N^2 = \frac{\sigma_0^2 \sigma^2}{N\sigma_0^2 + \sigma^2} \quad m_N = \frac{1}{N} \sum_{k=1}^N x_k$$

- 计算 $\mu$ 的贝斯估计

$$\hat{\mu} = \int \mu p(\mu | X) d\mu = \mu_N$$

## 3.2.2 贝叶斯估计和贝叶斯学习

### ○ 正态分布的贝叶斯学习

$$p(x | K) = \int p(x | \mu) p(\mu | K) d\mu$$
$$\sim N(\mu_N, \sigma^2 + \sigma_N^2)$$

$$\mu_N = \frac{N\sigma_0^2}{N\sigma_0^2 + \sigma^2} m_N + \frac{\sigma^2}{N\sigma_0^2 + \sigma^2} \mu_0$$

$N = 0$  时,  $\hat{\mu} = \mu_0$ ;                      若  $\sigma_0^2 = 0$ , 则  $\hat{\mu} \equiv \mu_0$

$N \rightarrow \infty$  时,  $\hat{\mu} \rightarrow m_N$                       若  $\sigma_0 \gg \sigma$ , 则  $\hat{\mu} = m_N$

## 3.3 总体分布的非参数估计

### 3.3.1 非参数估计的基本原理



- **非参数估计**：密度函数的形式未知，也不作假设，利用训练数据直接对概率密度进行估计。又称作**模型无关方法**
- **参数估计**需要事先假定一种分布函数，利用样本数据估计其参数。又称作**基于模型的方法**
- 常见的一些函数形式很难拟合实际的概率密度，经典的密度函数都是**单峰**的，而在许多实际情况中却是**多峰**的
- 两种常用的非参数估计方法：
  - Parzen窗法
  - $k_N$ -近邻法

### 3.3.1 非参数估计的基本原理

#### 直方图方法


- 非参数概率密度估计的最简单方法

- 1) 把 $x$ 的每个分量分成 $k$ 个等间隔小窗
- 2) 统计落入各个小舱内的样本数 $q_i$
- 3) 相应小舱的概率密度估计值为 $q_i/(NV)$



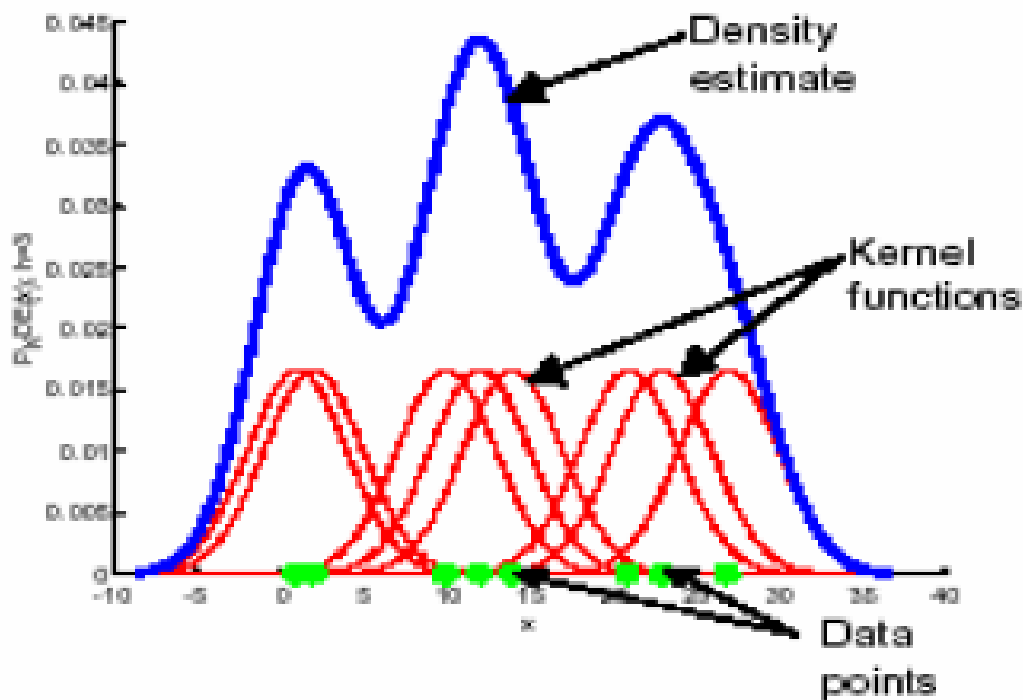
### 3.3.1 非参数估计的基本原理

- 估计的目的：从样本集  $K = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N\}$  估计样本空间中任何一点的概率密度  $p(\mathbf{x})$
- 基本思路的例子
  - 样本对概率密度的“贡献”
  - “贡献”函数



### 3.3.1 非参数估计的基本原理

- 基本方法：用某种核函数表示某一样本对待估计的密度函数的贡献，所有样本所作贡献的线性组合视作对某点概率密度 $p(x)$ 的估计
- 一个样本对自己所在位置的分布贡献最大，离得越远贡献越小



### 3.3.1 非参数估计的基本原理

- 样本集 $\mathbf{X}=\{x_1, x_2, \dots, x_N\}$ 中的样本，均从概率密度为 $p(x)$ 的总体中独立抽取
- 从 $k$ 个样本落入区域 $\mathbf{R}$ 的概率 $P \rightarrow$ 小区域的概率密度(当区域 $\mathbf{R}$ 的体积足够小，区域内 $p(x)$ 变化很小)

$$\hat{p}(\mathbf{x}) = \frac{P}{V} = \frac{k / N}{V}$$



### 3.3.1 非参数估计的基本原理

- 构造包含 $\mathbf{x}$ 的区域序列 $\mathbf{R}_1, \mathbf{R}_2, \dots, \mathbf{R}_N$ , 采用 $N$ 个样本的估计为

$$\hat{p}_N(\mathbf{x}) = \frac{P_N^{(k)}}{V_N} = \frac{k_N / N}{V_N}$$

- $\hat{p}_N(\mathbf{x})$ 收敛于 $p(\mathbf{x})$ 的条件:

$$(1) \lim_{N \rightarrow \infty} V_N = 0 \quad (2) \lim_{N \rightarrow \infty} k_N = \infty \quad (3) \lim_{N \rightarrow \infty} \frac{k_N}{N} = 0$$

- 区域序列的两种选择方法

- Parzen窗法

$$V_N = \frac{h_1}{\sqrt{N}}$$


- $k_N$ -近邻法

$$k_N = k_1 \sqrt{N}$$

### 3.3.2 Parzen窗法

- 区域 $\mathbf{R}_N$ 是一个 $d$ 维超立方体，棱长 $h_N$ ，体积 $V_N = h_N^d$
- 定义窗(核)函数

$$\varphi(u) = \begin{cases} 1 & |u_j| \leq \frac{1}{2}, j = 1, 2, \dots, d \\ 0 & \text{otherwise} \end{cases}$$



计数函数

- 落入超立方体内样本数 $k_N$

$$k_N = \sum_{i=1}^N \varphi\left(\frac{\mathbf{x} - \mathbf{x}_i}{h_N}\right)$$

- Parzen窗法估计的基本公式

$$\hat{p}_N(\mathbf{x}) = \frac{1}{N} \sum_{i=1}^N \frac{1}{V_N} \varphi\left(\frac{\mathbf{x} - \mathbf{x}_i}{h_N}\right)$$

### 3.3.2 Parzen窗法


- 窗函数需满足归一化条件（密度函数条件）

$$\begin{aligned} \varphi(u) &\geq 0 \\ \int \varphi(u) du &= 1 \end{aligned} \quad \Rightarrow \quad \hat{p}_N(\mathbf{x}) = \frac{1}{N} \sum_{i=1}^N \frac{1}{V_N} \varphi\left(\frac{\mathbf{x} - \mathbf{x}_i}{h_N}\right)$$

可作为密度函数的估计


- 常用的窗函数

- 方窗



- 正态窗

$$\varphi(u) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{u^2}{2}\right)$$



- 指数窗

$$\varphi(u) = \exp\{-|u|\}$$

### 3.3.2 Parzen窗法

- $h_N$ 是控制“窗”宽度的参数，根据样本的数量选择
  - 太大：平均化，分辨力低
  - 太小：统计变动大
- 定义窗函数（核函数）的方式

$$\delta_N(\mathbf{x}) = \frac{1}{V_N} \varphi\left(\frac{\mathbf{x}}{h_N}\right)$$

$$\delta_N(\mathbf{x}, \mathbf{x}_i) = \frac{1}{V_N} \varphi\left(\frac{\mathbf{x} - \mathbf{x}_i}{h_N}\right)$$

$$\hat{p}_N(\mathbf{x}) = \frac{1}{N} \sum_{i=1}^N \delta_N(\mathbf{x} - \mathbf{x}_i)$$

不同窗宽的估计效果有一定不同

### 3.3.2 Parzen窗法

- 估计密度函数是渐进无偏和平方误差一致的。其充要条件

$p(\mathbf{x})$ 在 $\mathbf{x}$ 点连续

窗函数满足密度函数的条件

$$\lim_{N \rightarrow \infty} h_N = 0$$

$$\lim_{N \rightarrow \infty} N h_N^d = \infty$$



$$h_N = \frac{h_1}{\sqrt[d+1]{N}}$$

## 3.3.2 Parzen窗法

- 例1: 对于一个二类 (  $\omega_1$  ,  $\omega_2$  ) 识别问题, 随机抽取 $\omega_1$ 类的6个样本  $\mathbf{X}=(\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_6)=(3.2, 3.6, 3, 6, 2.5, 1.1)$ 
  - 估计 $p(\mathbf{x}|\omega_1)$ 即 $p_N(\mathbf{x})$

解: 选正态窗函数


$$\varphi(u) = \frac{1}{\sqrt{2\pi}} \exp(-\frac{1}{2}u^2) \quad \therefore \varphi(u) = \varphi(\frac{|x - x_i|}{h_N}) = \frac{1}{\sqrt{2\pi}} \exp[-\frac{1}{2}(\frac{|x - x_i|}{h_N})^2]$$

$$\therefore V_N = h_N = \frac{h_1}{\sqrt{N}}, \text{其中选 } h_1 = 0.5\sqrt{6}, N = 6 \quad \therefore V_N = \frac{0.5\sqrt{6}}{\sqrt{6}} = 0.5$$

$$\therefore P_N(x) = \frac{1}{N} \sum_{i=1}^N \frac{1}{V_N} \varphi(\frac{|x - x_i|}{h_N}) = 0.134 \exp[-\frac{1}{2}(\frac{|x - 3.2|}{0.5})^2] + \dots + 0.134 \exp[-\frac{1}{2}(\frac{|x - 1.1|}{0.5})^2]$$

### 3.3.2 Parzen窗法

用图形表示是6个分别以3.2, 3.6, 3, 6, 2.5, 1.1为中心的丘形曲线(正态曲线), 而 $\hat{p}_N(x)$ 则是这些曲线的线性组合。



### 3.3.2 Parzen窗法

例2：设待估计的是个均值为0，方差为1的**正态密度**函数。若随机地抽取X样本中的1个、16个、256个作为学习样本,试用Parzen窗法估计 $p_N(x)$

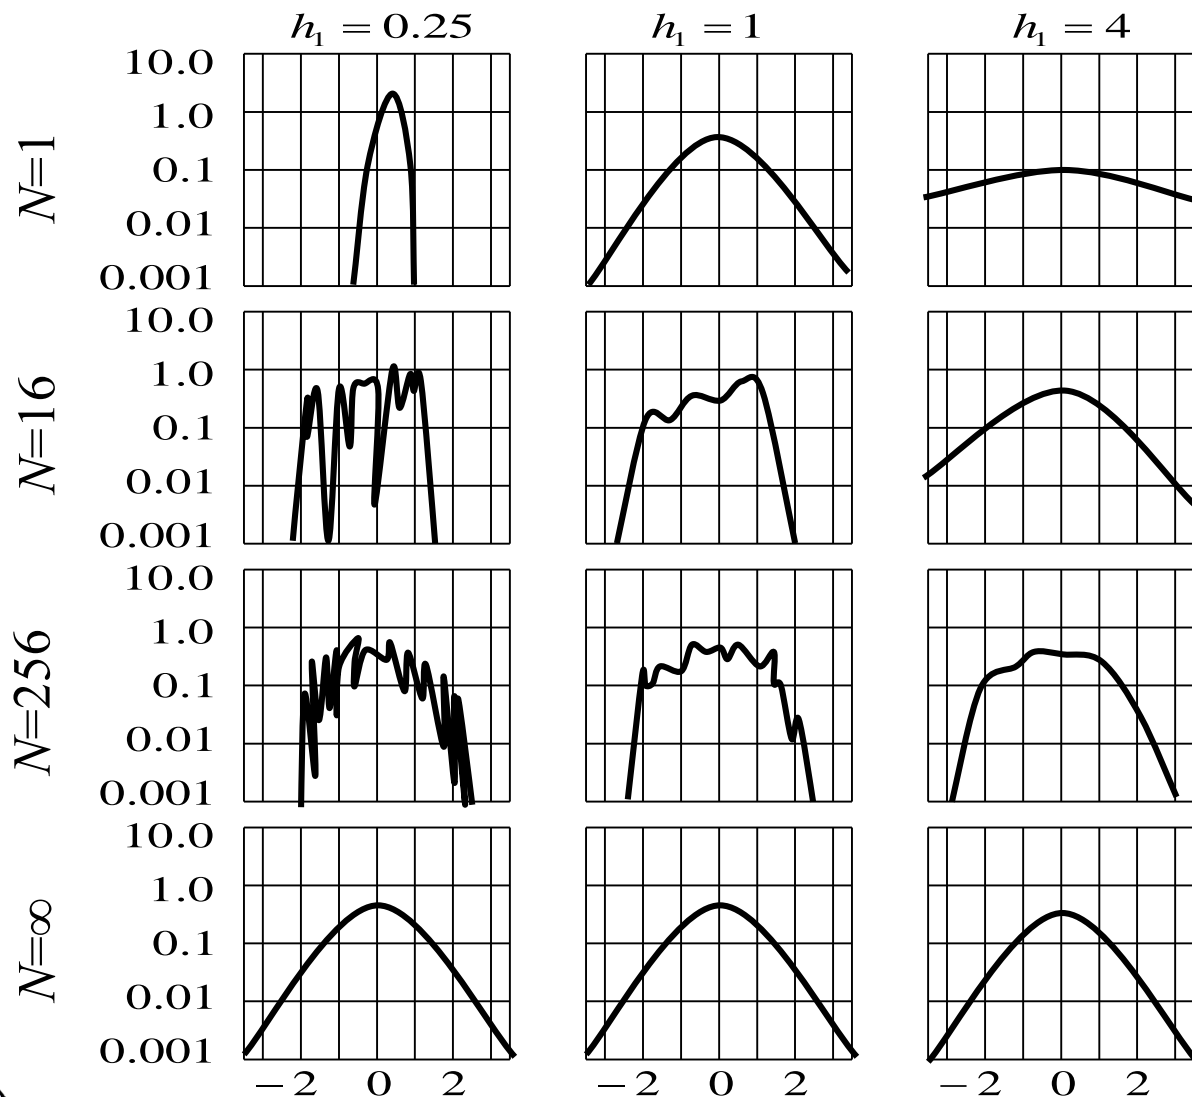
$$\text{设 } h_N = h_1 / \sqrt{N}$$

$$\begin{aligned} P_N(x) &= \frac{1}{N} \sum_{i=1}^N \frac{\sqrt{N}}{h_1} \varphi\left(\frac{|x - x_i|}{h_N}\right) \\ &= \frac{1}{h_1 \sqrt{N}} \sum_{i=1}^N \frac{1}{\sqrt{2\pi}} \exp\left[-\frac{1}{2} \left(\frac{|x - x_i| \sqrt{N}}{h_1}\right)^2\right] \end{aligned}$$



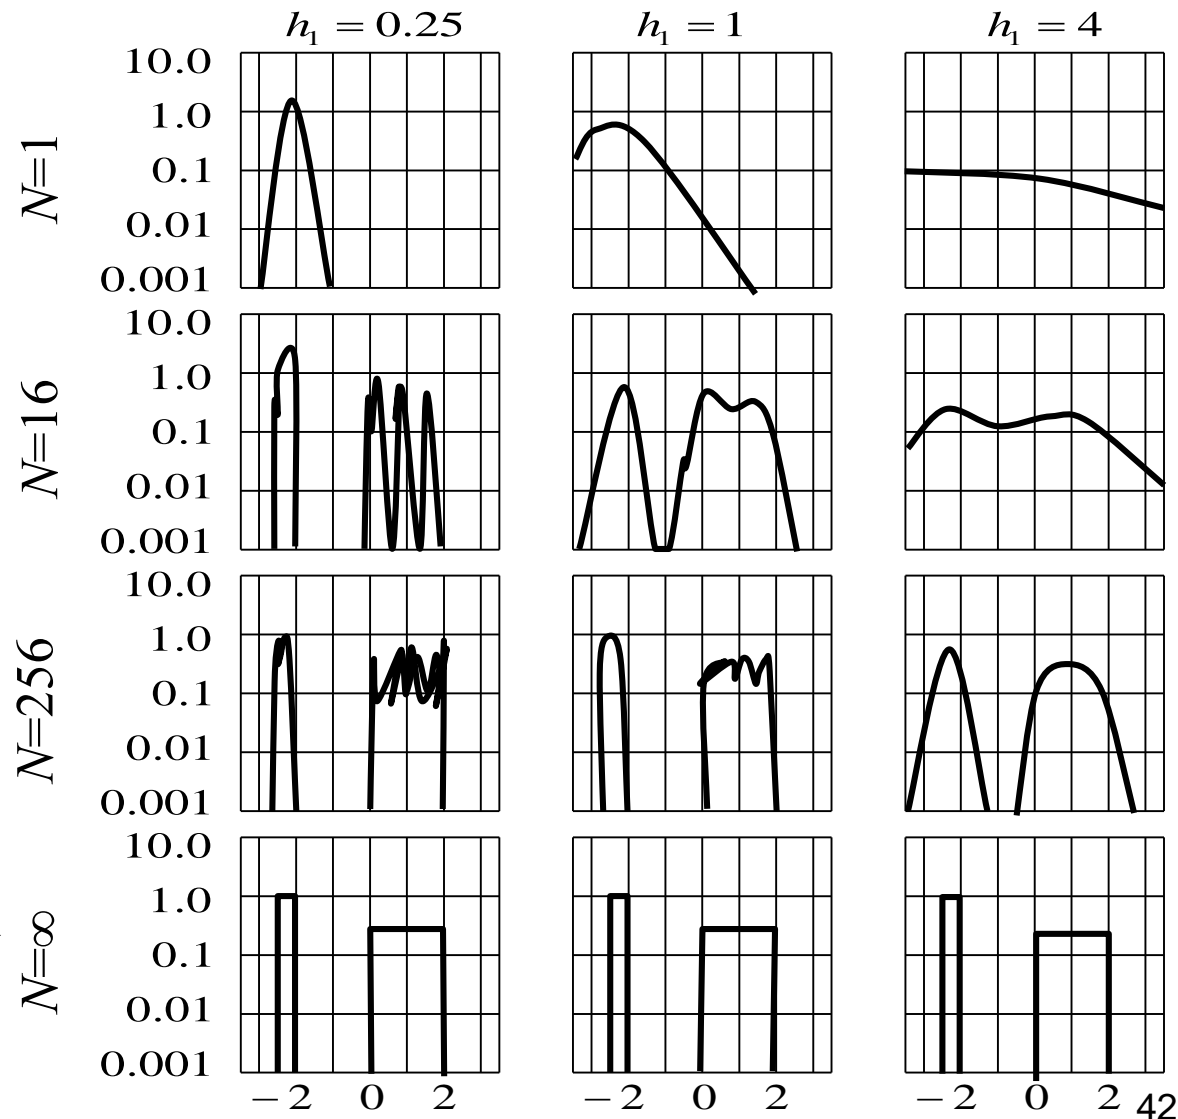

## 3.3.2 Parzen窗法

估计单一正态分布



## 3.3.2 Parzen窗法

估计两个均匀分布





## 3.3.2 Parzen窗法

- 由上例知窗口法的优点是应用的普遍性。对规则分布，非规则分布，单峰或多峰分布都可用此法进行密度估计
- 要求样本足够多，才能有较好的估计。因此使计算量，存储量增大

### 3.3.2 Parzen窗法

- 有限样本的影响

- 密度估计的均方误差:

$$E(\hat{p}_N(x) - p(x))^2 \cong O(N^{-\frac{4}{d+4}})$$

- ◆ **维数灾难**(Curse of Dimensionality): 当维数较高时, 样本数量无法达到精确估计的要求

N	d	$N^{-4/(d+4)}$
16	1	0.1
32	2	0.1
178	5	0.1
3162	10	0.1
3E+13	50	0.1

### 3.3.3 $k_N$ -近邻估计

- **Parzen**窗估计：窗宽固定，不同位置落在窗内的样本点的数目是变化的
- $k_N$ -近邻估计：把窗扩大到刚好覆盖 $k_N$ 个点。落在窗内的样本点的数目固定，窗宽是变化的。 $k_N$ 根据样本总数 $N$ 选择
- 概率密度估计表达式

$$\hat{p}_N(\mathbf{x}) = \frac{1}{V_N} \frac{k_N}{N}$$

- 收敛条件

$$\lim_{N \rightarrow \infty} k_N = \infty$$

$$\lim_{N \rightarrow \infty} k_N / N = 0$$

经验值

$$k_N = k_1 \sqrt{N}$$

### 3.3.3 $k_N$ -近邻估计

- $k_N$ -近邻估计概率密度函数，所需样本多、计算量大，因此有时并不利用它来进行密度函数估计，而是直接用它来进行样本分类——最近邻规则
  - 将 $x$ 归入到 $k_N$ 个最近邻中某一类样本最多的那个类别中
- 其它非参数估计方法
  - 有限项正交函数级数逼近法
- 有限样本下，**概率密度函数的估计问题**是一个很难的问题，**比分类器设计问题甚至更难**，也是一个更一般的问题——→**直接设计分类器**



## 3.4 高斯混合模型 (GMM)

- GMM的表达
- GMM参数计算
- GMM应用举例

## 3.4.1 高斯模型

- 是一种参数化模型，用高斯密度函数估计目标的分布

- 单高斯 (Single Gaussian Model)

$$N(x; \mu, \Sigma) = \frac{1}{(2\pi)^{d/2} \sqrt{|\Sigma|}} \exp \left\{ -\frac{1}{2} (x - \mu)^T \Sigma^{-1} (x - \mu) \right\} \quad x \in R^d$$

- 高斯混合模型 (Gaussian mixture model)

$$\Phi(x; \theta) = \sum_{i=1}^k \pi_i N(x; \mu_i, \Sigma_i)$$

$$\theta = \{\mu_1, \Sigma_1, \dots, \mu_i, \Sigma_i, \dots, \mu_k, \Sigma_k\}$$






## 3.4.2 高斯混合模型(GMM)

公式表达: 
$$\Phi(x; \theta) = \sum_{i=1}^k \pi_i N(x; \mu_i, \Sigma_i)$$

由 $k$ 个加权( $\pi_i$ )的高斯函数( $N(\cdot)$ )的线性组合构成, 其中:

参数空间:  $\theta = \{\pi_1, \mu_1, \Sigma_1, \dots, \pi_i, \mu_i, \Sigma_i, \dots, \pi_k, \mu_k, \Sigma_k\} \quad |\theta| = 3 * k$





# 高斯混合模型 (GMM)

- GMM的表达式
- **GMM参数计算**
- GMM应用举例

### 3.4.3 GMM参数学习

➡ 给定一些观察数据 $\mathbf{X}=\{\mathbf{x}\}$ , 假设 $\{\mathbf{x}\}$ 符合如下的混合高斯分布

$$p(\mathbf{x}; \boldsymbol{\theta}) = \sum_{i=1}^K \pi_i N(\mathbf{x}; \boldsymbol{\mu}_i, \boldsymbol{\Sigma}_i)$$

求解一组混合高斯模型的参数 $\boldsymbol{\theta}$ , 使得\*:

$$\begin{aligned} \operatorname{argmax}_{\boldsymbol{\theta}} P(\mathbf{X}; \boldsymbol{\theta}) &= \operatorname{argmax}_{\boldsymbol{\theta}} \prod_i^N p(\mathbf{x}_i; \boldsymbol{\theta}), \\ \text{s.t. } \sum_k^K \pi_k &= 1, 0 \leq \pi_k \leq 1 \end{aligned}$$

\*注意: 对于观察集 $\{\mathbf{x}\}$ 中的各个观察值 $\mathbf{x}_i$ , 这里认为相互之间独立。

### 3.4.3 GMM参数学习

- 对目标函数取对数：

$$\ln(p(X; \Theta)) = \sum_{i=1}^N \ln p(x_i; \Theta) = \sum_{i=1}^N \ln \left( \sum_{k=1}^K \pi_k N(x_i; \mu_k, \Sigma_k) \right)$$

- 可以看出目标函数是和的对数，优化问题麻烦，简化的问题：某混合高斯分布一共有K个分布，对于每一个观察到的 $\mathbf{x}$ ，如果我们同时还知道它是属于K中哪一个分布的，则可以直接求解出各个高斯分布的参数。
- 因此引入隐变量 $\mathbf{Z}$ ，用于表示样本 $\{\mathbf{x}\}$ 输入哪一个高斯分布

### 3.4.3 GMM参数学习

- 定义  $Z_i = \{z_{i1}, \dots, z_{iK}\}$ ,  $z_{ik}$  表示  $x_i$  是否属于第  $k$  个高斯函数,  $z_{ik}$  只有两个取值 0、1, 即  $z_{ik}=1$  表示  $x_i$  属于第  $k$  个高斯函数,  $z_{ik}=0$  表示  $x_i$  不属于第  $k$  个高斯函数。
- 那么, 有:

$$\sum_{k=1}^K z_{ik} = 1$$

$$p(Z_i) = \prod_{k=1}^K \pi_k^{z_{ik}}$$



### 3.4.3 GMM参数学习

#### ○ 引入Z后

$$p(x_i | z_{ik} = 1; \Theta) = N(x_i | \mu_k, \Sigma_k)$$

#### • 从而得到

$$p(x_i | Z_i; \Theta) = \prod_{k=1}^K N(x_i | \mu_k, \Sigma_k)^{z_{ik}}$$

注意：这里 $z_{ik}$ 只有0和1的选择

### 3.4.3 GMM参数学习

- 在简化问题中，我们实际的观察变量是  $\{X, Z\}$ , 根据一下两个公式

$$p(Z_i) = \prod_{k=1}^K \pi_k^{z_{ik}} \quad p(x_i | Z_i; \Theta) = \prod_{k=1}^K N(x_i | \mu_k, \Sigma_k)^{z_{ik}}$$

- 可以得到

$$p(X, Z; \Theta) = \prod_{n=1}^N \prod_{k=1}^K \pi_k^{z_{ik}} N(x_i | \mu_k, \Sigma_k)^{z_{ik}}$$

注意：这里N是 $X=\{x\}$ 集合的大小。



### 3.4.3 GMM参数学习

#### 比较原问题和简化问题

$$\ln(p(X; \Theta)) = \sum_{i=1}^N \ln p(x_i; \Theta) = \sum_{i=1}^N \ln \left( \sum_{k=1}^K \pi_k N(x_i; \mu_k, \Sigma_k) \right)$$

$$\begin{aligned} \ln p(X, Z; \Theta) &= \ln \left\{ \prod_{n=1}^N \prod_{k=1}^K \pi_k^{z_{ik}} N(x_i | \mu_k, \Sigma_k)^{z_{ik}} \right\} \\ &= \sum_{n=1}^N \sum_{k=1}^K z_{ik} \{ \ln \pi_k + \ln N(x_i | \mu_k, \Sigma_k) \} \end{aligned}$$

- 后者的ln直接作用于正态分布，使正态分布由乘的e指数形式变为加的简单形式



### 3.4.3 GMM参数学习

$$\ln p(\mathbf{X}, \mathbf{Z}; \Theta) = \sum_{i=1}^N \sum_{k=1}^K z_{ik} \{ \ln \pi_k + \ln N(x_i | \mu_k, \Sigma_k) \}$$

- 为了最大化上式，由于 $z_{ik}$ 已知，我们可以把上式按观察到的 $(\mathbf{x}, \mathbf{z})$ 分为 $K$ 组，即按照所属的高斯函数进行分组

$$\begin{aligned} \ln p(\mathbf{X}, \mathbf{Z}; \Theta) = & \sum_{i \in C_1} (\ln \pi_1 + \ln N(x_i | \mu_1, \Sigma_1)) + \sum_{i \in C_2} (\ln \pi_2 + \ln N(x_i | \mu_2, \Sigma_2)) \\ & + \dots + \sum_{i \in C_K} (\ln \pi_K + \ln N(x_i | \mu_K, \Sigma_K)) \end{aligned}$$

注意：用到 $z_{ik}$ 的取值，所以 $z_{ik}$ 不会再出现在公式中。

### 3.4.3 GMM参数学习

- 因为我们假定 $z_{ik}$ 已知，因而最大化某一个高斯函数

$$\sum_{i \in C_k} (\ln \pi_k + \ln N(x_i | \mu_k, \Sigma_k))$$

是可以数值求解的。

- 假定 $C_k$ 中含有 $N_k$ 个样本，则

$$\sum_{i \in C_k} (\ln \pi_k + \ln N(x_i | \mu_k, \Sigma_k)) = N_k \ln \pi_k + \ln N(X | \mu_k, \Sigma_k)$$

注意：这里 $X$ 表示的是 $x_i$ 的联合， $X$ 表示的是仅属于 $C_k$ 的样本的联合。

### 3.4.3 GMM参数学习

#### ○ 对于单高斯函数

$$\ln N(X | \mu_k, \Sigma_k) = -\frac{N_k D}{2} \ln(2\pi) - \frac{N_k}{2} |\Sigma| - \frac{1}{2} \sum_{i=1}^{N_k} (x_i - \mu_k)^T \Sigma_k^{-1} (x_i - \mu_k)$$

#### • 对上式 $\mu_k$ 求偏导

$$\frac{\partial}{\partial \mu_k} \ln N(X | \mu_k, \Sigma_k) = \sum_{i=1}^{N_k} \Sigma_k^{-1} (x_i - \mu_k)$$

#### • 令上式等于0，则有

$$\mu_k = \frac{1}{N_k} \sum_{i=1}^{N_k} x_i$$

#### • 同理，可以得到

$$\Sigma_k = \frac{1}{N_k} \sum_{i=1}^{N_k} (x_i - \mu_k)(x_i - \mu_k)^T$$

### 3.4.3 GMM参数学习

- 在 $z_{ik}$ 已知的情况下，我们求出了高斯函数的数值解：

$$\mu_k = \frac{1}{N_k} \sum_{i=1}^N z_{ik} x_i$$

$$\Sigma_k = \frac{1}{N_k} \sum_{i=1}^N z_{ik} (x_i - \mu_k)(x_i - \mu_k)^T$$

其中

$$N_k = \sum_{i=1}^N z_{ik}$$

### 3.4.3 GMM参数学习

现在，假定已知所有 $\mu_k$ 和 $\Sigma_k$ ，来求解 $\pi_k$ ，因为 $\pi_k$ 满足 $\sum_{k=1}^K \pi_k = 1$ ，可以对 $\ln p(X, Z | \Theta)$ 应用拉格朗日乘法：

$$\begin{aligned} L &= \ln p(X, Z; \Theta) + \lambda \left( \sum_{k=1}^K \pi_k - 1 \right) \\ &= \sum_{i=1}^N \sum_{k=1}^K z_{ik} \{ \ln \pi_k + \ln N(x_i | \mu_k, \Sigma_k) \} + \lambda \left( \sum_{k=1}^K \pi_k - 1 \right) \end{aligned}$$

• 对 $L$ 中 $\pi_k$ 和 $\lambda$ 求导并令其为0，得到

$$\left. \begin{aligned} \frac{\partial L}{\partial \lambda} &= \sum_{k=1}^K \pi_k - 1 = 0 \\ \frac{\partial L}{\partial \pi_k} &= \sum_{i=1}^N z_{ik} + \lambda = 0 \end{aligned} \right\} \begin{aligned} \lambda &= - \sum_{i=1}^N \sum_{k=1}^K z_{ik} = -N \\ \pi_k &= \frac{\sum_{i=1}^N z_{ik}}{N} = \frac{N_k}{N} \end{aligned}$$

### 3.4.3 GMM参数学习

- 引入隐变量 $Z$ 后，我们得到了最大化目标函数的结果

$$\ln p(X, Z; \Theta) = \sum_{i=1}^N \sum_{k=1}^K z_{ik} \{ \ln \pi_k + \ln N(x_i | \mu_k, \Sigma_k) \}$$

$$\mu_k = \frac{1}{N_k} \sum_{i=1}^N z_{ik} x_i$$

$$\Sigma_k = \frac{1}{N_k} \sum_{i=1}^N z_{ik} (x_i - \mu_k)(x_i - \mu_k)^T$$

$$\pi_k = \frac{\sum_{i=1}^N z_{ik}}{N} = \frac{N_k}{N}$$

$$N_k = \sum_{i=1}^N z_{ik}$$



通过上面的公式，可以看出如果能够知道每一个 $z_{ik}$ 的取值，那么就能求解出最大化目标函数的参数取值，但事实上给定一组观察数据 $\{x\}$ 后，是无法获取 $z_{ik}$ 的，因此我们将用 $z_{ik}$ 的均值 $E\{z_{ik}\}$ 来代替。



$$\mu_k = \frac{1}{N_k} \sum_{i=1}^N E(z_{ik}) x_i$$

$$\Sigma_k = \frac{1}{N_k} \sum_{i=1}^N E(z_{ik}) (x_i - \mu_k)(x_i - \mu_k)^T$$

$$\pi_k = \frac{\sum_{i=1}^N E(z_{ik})}{N} = \frac{N_k}{N}$$

$$N_k = \sum_{i=1}^N E(z_{ik})$$

### 3.4.3 GMM参数学习

#### 进一步解释

$$\mu_k = \frac{1}{N_k} \sum_{i=1}^N E(z_{ik}) x_i$$

$$\Sigma_k = \frac{1}{N_k} \sum_{i=1}^N E(z_{ik}) (x_i - \mu_k)(x_i - \mu_k)^T$$

$$\pi_k = \frac{\sum_{i=1}^N E(z_{ik})}{N} = \frac{N_k}{N}$$


$$N_k = \sum_{i=1}^N E(z_{ik})$$

现在的问题转化为如何求解 $E\{z_{ik}\}$ ?

为了求解 $E\{z_{ik}\}$ ，我们假定已知一组参数取值 ( $\Theta$ 的取值)，从而求解 $z_{ik}$ 的后验数学期望 $E\{z_{ik} | \Theta\}$ ，得到 $E\{z_{ik}\}$ 我们再计算 $\Theta$ 。

显然求得的 $\Theta$ 是给定 $E\{z_{ik}\}$ 情况下的结果，并不一定是目标函数的解，为此：

引入一种迭代思想，迭代计算 $E\{z_{ik}\}$ 和 $\Theta$



### 3.4.3 GMM参数学习

$$\begin{aligned} E(z_{ik} | \Theta) &= \sum_{n=1}^N \sum_{z_{ik}} z_{ik} p(z_{ik} | x_n, \Theta) \\ &= \sum_{z_{ik}} z_{ik} p(z_{ik} | x_i, \Theta) \quad \leftarrow z_{ik} \text{只与} x_i \text{有关} \\ &= \sum_{z_{ik}} z_{ik} \frac{p(z_{ik} | \Theta) p(x_i | z_{ik}, \Theta)}{p(x_i | \Theta)} \quad \leftarrow \text{贝叶斯公式} \\ &= 1 \cdot \frac{p(z_{ik} = 1 | \Theta) p(x_i | z_{ik} = 1, \Theta)}{p(x_i | \Theta)} + 0 \cdot \frac{p(z_{ik} = 0 | \Theta) p(x_i | z_{ik} = 0, \Theta)}{p(x_i | \Theta)} \\ &= \frac{p(z_{ik} = 1 | \Theta) p(x_i | z_{ik} = 1, \Theta)}{p(x_i | \Theta)} \quad \leftarrow z_{ik} \text{只有} 0、1 \text{取值} \\ &= \frac{\pi_k N(x_i | \mu_k, \Sigma_k)}{\sum_{j=1}^K \pi_j N(x_i | \mu_j, \Sigma_j)} \quad \leftarrow \text{公式展开} \end{aligned}$$




### 3.4.3 GMM参数学习

#### 小结

E-step: 给定  $\Theta$  计算  $E\{z_{ik} | \Theta\}$

$$E(z_{ik} | \Theta) = \frac{\pi_k N(x_i | \mu_k, \Sigma_k)}{\sum_{j=1}^K \pi_j N(x_i | \mu_j, \Sigma_j)}$$

E-step



M-step

M-step: 给定  $E\{z_{ik} | \Theta\}$  更新  $\Theta$

$$\begin{aligned}\mu_k &= \frac{1}{N_k} \sum_{i=1}^N E(z_{ik}) x_i \\ \Sigma_k &= \frac{1}{N_k} \sum_{i=1}^N E(z_{ik}) (x_i - \mu_k)(x_i - \mu_k)^T \\ \pi_k &= \frac{\sum_{i=1}^N E(z_{ik})}{N} = \frac{N_k}{N} \\ N_k &= \sum_{i=1}^N E(z_{ik})\end{aligned}$$





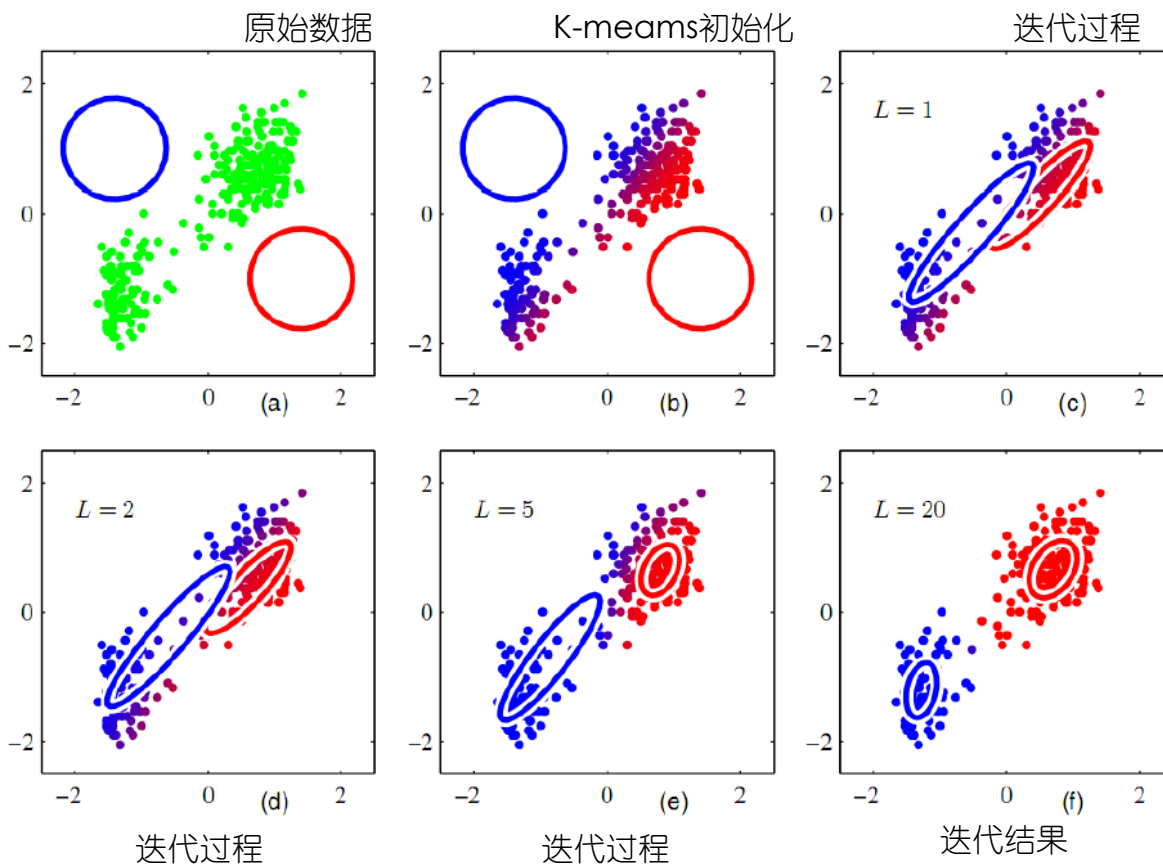
## 3.4.3 GMM参数学习

### ○ 算法流程

1. 初始化一组参数 $\Theta$ ，如K-means方法；
2. 根据参数 $\Theta$ 计算 $E\{z_{ik} | \Theta\}$ ；
3. 根据 $E\{z_{ik} | \Theta\}$ 更新参数 $\Theta$ ；
4. 迭代2.3.直到达到某种阈值条件，如 $|\Theta^{\text{new}} - \Theta^{\text{old}}|$ ,  $|p(X|\Theta^{\text{new}}) - p(X|\Theta^{\text{old}})|$ ；

### 3.4.3 GMM参数学习

#### ○ GMM, $K=2$



### 3.4.4 GMM应用

## 背景模型：对图像中的场景进行建模，从而进行运动检测。

**要点1：**将图像中的每个图像单位(像素，块等)看成是从混合高斯分布样本中采样得到的随机变量；

**要点2：**根据先验知识，每个像素点是前景或背景的先验概率可以估值；

**要点3：**考虑到背景的多模态和复杂度，一般的混合高斯模型采用3-5个单高斯模型进行混合。

视频帧

背景图像

前景图像



### 3.4.4 GMM应用

- 用K个高斯模型来表征图像中各个像素点的特征
- $I_{xy,t}$ 属于背景区域的概率密度:

$$f(I_{xy,t}) = \sum_{k=1}^K \pi_{xy,k,t} \cdot N(I_{xy,t}, \mu_{xy,k,t}, \sigma_{xy,k,t}), \quad \sum_{k=1}^K \pi_{xy,k,t} = 1$$

$I_{xy,t}$ 表示 $t$ 时刻图像 $I$ 中的 $xy$ 位置的像素特征。

模型主要步骤:

- 1, 模型初始化;
- 2, 背景描述;
- 3, 前景判决;
- 4, 模型更新。