



第四章 判别國方程

任课教师：柳欣老师

email: starxliu@163.com



4.1 判别域代数界面方程法

有
监
督
分
类

- 1 用判别域界面方程分类的概念
- 2 线性判别函数
- 3 判别函数值的鉴别意义、权空间及解空间
- 4 Fisher线性判别
- 5 一次准则函数及梯度下降法
- 6 二次准则函数及其解法
- 9 广义线性判别函数



4.1 判别域代数界面方程法

1 用判别域界面方程分类的概念


1. 分类的基本原理

不同模式对应特征点在不同的区域中散布。运用已知类别的训练样本进行学习, 产生若干个代数界面 $d(\bar{x}) = 0$, 将特征空间划分成一些互不重叠的子区域。

2. 判别函数


表示界面的函数 $d(\bar{x})$ 称为判别函数 (Discriminant Function)。

4.1 判别域代数界面方程法




两类的分类问题，它们的边界线就是一个判别函数

4.1 判别域代数界面方程法



两类问题中线性不可分的实例

4.1 判别域代数界面方程法



三类的分类问题，它们的边界线也是一个判别函数



4.1 判别域代数界面方程法

3. 线性可分的定义

对于来自两类的一组模式 $\vec{x}_1, \vec{x}_2, \dots, \vec{x}_N$, 如果能用一个线性判别函数正确分类, 则称他们是线性可分的。

4. 本章分类方法的基本技术思路

第一步: 利用训练样本求出分类器/判别函数

第二步: 利用判别函数对未知类别样本分类

4.1 判别域代数界面方程法

将二维模式推广到 n 维，线性判别函数的一般形式为：

$$d(\mathbf{X}) = w_1x_1 + w_2x_2 + \dots + w_nx_n + w_{n+1} = \mathbf{W}_0^T \mathbf{X} + w_{n+1} \quad (3-2)$$

式中： $\mathbf{X} = [x_1, x_2, \dots, x_n]^T$

$\mathbf{W}_0 = [w_1, w_2, \dots, w_n]^T$ ：权向量，即参数向量。

$$d(\mathbf{X}) = w_1x_1 + w_2x_2 + \dots + w_nx_n + w_{n+1} \cdot 1$$

$$= \begin{bmatrix} w_1 & w_2 & \dots & w_n & w_{n+1} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \\ 1 \end{bmatrix} = \mathbf{W}^T \mathbf{X}$$


式中：

$$\mathbf{X} = [x_1, x_2, \dots, x_n, 1]^T$$

为增广模式向量。

$$\mathbf{W} = [w_1, w_2, \dots, w_n, w_{n+1}]^T$$

为增广权向量，



1. 两类情况

$$d(\mathbf{X}) = \mathbf{W}^T \mathbf{X} \begin{cases} > 0, & \text{若 } \mathbf{X} \in \omega_1 \\ < 0, & \text{若 } \mathbf{X} \in \omega_2 \end{cases}$$

$d(\mathbf{X}) = 0$: 不可判别情况, 可以 $\mathbf{X} \in \omega_1$ 或 $\mathbf{X} \in \omega_2$ 或拒绝

2. 多类情况

对 M 个线性可分模式类, $\omega_1, \omega_2, \dots, \omega_M$, 有三种划分方式:

$\omega_i / \bar{\omega}_i$ 两分法

ω_i / ω_j 两分法


ω_i / ω_j 两分法特例

4.1 判别域代数界面方程法

一、两类问题

对于两类问题, 待识别模式增广特征矢量 \vec{x} 可通过下面的判别规则进行分类识别: 设 $d(\vec{x})$ 为判别函数,

$$d(\vec{x}) = \vec{w}'\vec{x} \begin{cases} > 0 \Rightarrow \vec{x} \in \omega_1 \\ < 0 \Rightarrow \vec{x} \in \omega_2 \\ = 0 \Rightarrow \vec{x} \in \omega_i \text{ 或拒判} \end{cases}$$



4.2 判别域代数界面方程多类法

二、多类问题

处理多类问题主要有以下几种方法：

1. $\omega_i / \bar{\omega}_i$ 两分法（第一种情况）


基本思想：将属于 ω_i 类和不属于 ω_i 类的模式划分开。 C 类问题转化为 $C-1$ 个两类问题。可建立 C 个判别函数。

$$d_i(\bar{x}) = \bar{w}_i' \bar{x} \quad (i = 1, 2, \dots, c)$$

通过训练, 其中每个判别函数都具有下面的性质:

$$d_i(\bar{x}) \begin{cases} > 0, \text{若 } \bar{x} \in \omega_i, \\ < 0, \text{若 } \bar{x} \in \bar{\omega}_i, \end{cases} \quad (i = 1, 2, \dots, c)$$

4.2 判别域代数界面方程多类法



多类问题图例（第一种情况）

1、第一种情况（续）

判别规则为：

如果 $\begin{cases} d_i(\vec{x}) > 0 \\ d_j(\vec{x}) \leq 0 \end{cases} \quad \forall j \neq i$ 则判 $\vec{x} \in \omega_i$


比如对图三类问题，
如果对于任一模式 \vec{x} 如
果它的

$$d_1(\vec{x}) > 0$$

$$d_2(\vec{x}) < 0$$

$$d_3(\vec{x}) < 0$$

则该模式属于 ω_1 类。






另一种情况是IR2区域, 判别函数都为负值。IR1, IR2, IR3, IR4 都为不

另一种情况是IR2区域，判别函数都为负值。IR1，IR2，IR3，IR4。都为不确定区域。



对某一模式区, $d_i(\mathbf{X}) > 0$ 的条件超过一个, 或全部的 $d_i(\mathbf{X}) < 0$, 分类失效。相当于不确定区(indefinite region, IR)。



此法将 M 个多类问题分成 M 个两类问题, 识别每一类均需 M 个判别函数。识别出所有的 M 类仍是这 M 个函数。

1、第一种情况（续）

例 已知三类 $\omega_1, \omega_2, \omega_3$ 的判别函数分别为：

$$\begin{cases} d_1(\vec{x}) = -x_1 + x_2 \\ d_2(\vec{x}) = x_1 + x_2 - 5 \\ d_3(\vec{x}) = -x_2 + 1 \end{cases}$$

求：当 $\vec{x} = (x_1, x_2)' = (6, 5)'$ 时属于哪一类？

解： 三个判别边界分别为：

$$\begin{cases} d_1(\vec{x}) = -x_1 + x_2 = 0 \\ d_2(\vec{x}) = x_1 + x_2 - 5 = 0 \\ d_3(\vec{x}) = -x_2 + 1 = 0 \end{cases}$$

1、第一种情况（续）

将 $\vec{x} = (x_1, x_2)' = (6, 5)'$ 代入方程组：

$$\begin{cases} d_1(\vec{x}) = -x_1 + x_2 \\ d_2(\vec{x}) = x_1 + x_2 - 5 \\ d_3(\vec{x}) = -x_2 + 1 \end{cases}$$

得：


$$d_1(\vec{x}) = -1, d_2(\vec{x}) = 6, d_3(\vec{x}) = -4.$$

结论： 因为

$$d_1(x) < 0, d_2(x) > 0, d_3(x) < 0$$

所以它属于 ω_2 类。

1、第一种情况（续）



2. ω_i/ω_j 两分法 (第二种情况)

此类方法同样存在不确定区。

对 C 类中的任意两类 ω_i 和 ω_j 都分别建立一个判别函数, 这个判别函数将属于 ω_i 的模式与属于 ω_j 的模式区分开。此函数对其他模式分类不提供信息, 因此总共需要 $c(c-1)/2$ 个这样的判别函数。

通过训练得到区分两类 ω_i 和 ω_j 的判别函数为:

$$d_{ij}(\bar{x}) = \bar{w}_{ij}' \bar{x} \quad (i, j = 1, 2, \dots, c; i \neq j)$$

它具有性质:


$$d_{ij}(\bar{x}) = \bar{w}_{ij}' \bar{x} \begin{cases} > 0, \text{若 } \bar{x} \in \omega_i \\ < 0, \text{若 } \bar{x} \in \omega_j \end{cases}$$

$$d_{ij}(\bar{x}) = -d_{ji}(\bar{x})$$

判别规则是:

如果: $d_{ij}(x) > 0, \forall j \neq i$ 则判 $x \in \omega_i$

2、第二种情况（续）



多类问题图例（第二种情况）



例：设有一个二维三类问题，三个判别函数为：

$$d_{12}(\vec{x}) = -x_1 - x_2 + 5 \quad d_{13}(\vec{x}) = -x_1 + 3 \quad d_{23}(\vec{x}) = -x_1 + x_2$$

求模式 $\vec{x} = (4, 3)'$ 属于哪一类？

解：将模式 $\vec{x} = (4, 3)'$ 代入 $d_{ij}(\vec{x})$ 有：


$$d_{12}(\vec{x}) = -2 \Rightarrow \vec{x} \notin \omega_1$$

$$d_{23}(\vec{x}) = -1 \Rightarrow \vec{x} \notin \omega_2$$


$$d_{13}(\vec{x}) = -1 \Rightarrow \vec{x} \notin \omega_1$$


上面三式等效为： $d_{21}(\vec{x}) = 2 \quad d_{31}(\vec{x}) = 1 \quad d_{32}(\vec{x}) = 1$


由于 $d_{3j}(\vec{x}) > 0 \ (j = 1, 2)$ ，所以判 $\vec{x} \in \omega_3$



ω_i / ω_j 两分法例题图示







3. 没有不确定区的 ω_i/ω_j 两分法（第三种情况）

令方法2中的判别函数为：

$$d_{ij}(\bar{x}) = d_i(\bar{x}) - d_j(\bar{x}) = (\vec{w}_i - \vec{w}_j)' \bar{x}$$

则 $d_{ij}(\bar{x}) > 0$ 等价于 $d_i(\bar{x}) > d_j(\bar{x})$ ，于是对每一类 ω_i 均建立一个判别函数 $d_i(\bar{x})$ ， C 类问题有 C 个判别函数

$$d_i(\bar{x}) = \vec{w}_i' \bar{x} \quad i = 1, 2, \dots, c$$


故判决规则成为：

如果 $d_i(\bar{x}) > d_j(\bar{x}) \quad \forall j \neq i$ 则判 $\bar{x} \in \omega_i$

判决规则的另一种表达形式

如果 $d_i(\bar{x}) = \max_j [d_j(\bar{x})]$ 则判 $\bar{x} \in \omega_i$

3、第三种情况（续）



多类问题图例（第三种情况）



例：设有一个二维三类问题，三个判别函数为：

$$d_1(\vec{x}) = -x_1 + x_2 \quad d_2(\vec{x}) = x_1 + x_2 - 1 \quad d_3(\vec{x}) = -x_2$$

求模式 $\vec{x} = (1, 1)'$ 属于哪一类？

解：将模式 $\vec{x} = (1, 1)'$ 代入上面各式得：

$$d_1(\vec{x}) = 0 \quad d_2(\vec{x}) = 1 \quad d_3(\vec{x}) = -1$$

$$\text{由于} \quad \begin{cases} d_2(\vec{x}) > d_3(\vec{x}) \\ d_2(\vec{x}) > d_1(\vec{x}) \end{cases} \quad \text{所以} \quad \vec{x} \in \omega_2$$



上述三种方法小结:

当 $c > 3$ 时, ω_i / ω_j 法比 $\omega_i / \overline{\omega_i}$ 法需要更多的判别函数式, 这是一个缺点。

但是 $\omega_i / \overline{\omega_i}$ 法是将 ω_i 类与其余的 $c - 1$ 类区分开, 而 ω_i / ω_j 法是将 ω_i 类和 ω_j 类分开, 显然 ω_i / ω_j 法使模式更容易线性可分, 这是它的优点。

方法(3)判别函数的数目和方法(1)相同, 但没有不确定区, 分析简单, 是最常用的一种方法。



判别函数值的鉴别意义、权空间及解空间

3.3.1. 判别函数值的大小、正负的数学意义

n 维特征空间 X^n 中, 两类问题的线性判别界面方程为:

$$d(\vec{x}) = \vec{w}_0' \vec{x} + w_{n+1}$$



4.3 线性判别函数的几何性质

模式空间与超平面

1. 概念

模式空间：以 n 维模式向量 \mathbf{X} 的 n 个分量为坐标变量的欧氏空间。

模式向量的表示：点、有向线段。


线性分类：用 $d(\mathbf{X})$ 进行分类，相当于用超平面 $d(\mathbf{X})=0$ 把模式空间分成不同的决策区域。

2. 讨论

设判别函数： $d(\mathbf{X}) = \mathbf{W}_0^T \mathbf{X} + w_{n+1}$

式中， $\mathbf{W}_0 = [w_1, w_2, \dots, w_n]^T$ $\mathbf{X} = [x_1, x_2, \dots, x_n]^T$

超平面： $d(\mathbf{X}) = \mathbf{W}_0^T \mathbf{X} + w_{n+1} = 0$



(1) 模式向量 X_1 和 X_2 在超平面上

$$\mathbf{W}_0^T \mathbf{X}_1 + w_{n+1} = \mathbf{W}_0^T \mathbf{X}_2 + w_{n+1}$$


$$\mathbf{W}_0^T (\mathbf{X}_1 - \mathbf{X}_2) = 0$$


—— \mathbf{W}_0 是超平面的法向量，
方向由超平面的负侧指向正侧。

设超平面的单位法线向量为 \mathbf{U} :

$$\mathbf{U} = \frac{\mathbf{W}_0}{\|\mathbf{W}_0\|}$$

$$\|\mathbf{W}_0\| = \sqrt{w_1^2 + w_2^2 + \cdots + w_n^2}$$





(2) \mathbf{X} 不在超平面上

将 \mathbf{X} 向超平面投影得向量 \mathbf{X}_p ,
构造向量 \mathbf{R} :


$$\mathbf{R} = r \cdot \mathbf{U} = r \frac{\mathbf{W}_0}{\|\mathbf{W}_0\|}$$

r : \mathbf{X} 到超平面的代数距离。有

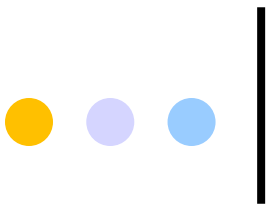
$$\mathbf{X} = \mathbf{X}_p + \mathbf{R} = \mathbf{X}_p + r \frac{\mathbf{W}_0}{\|\mathbf{W}_0\|}$$

$$\begin{aligned} d(\mathbf{X}) &= \mathbf{W}_0^T (\mathbf{X}_p + r \frac{\mathbf{W}_0}{\|\mathbf{W}_0\|}) + w_{n+1} = (\mathbf{W}_0^T \mathbf{X}_p + w_{n+1}) + \mathbf{W}_0^T \cdot r \frac{\mathbf{W}_0}{\|\mathbf{W}_0\|} \\ &= r \|\mathbf{W}_0\| \end{aligned}$$

—— 判别函数 $d(\mathbf{X})$ 正比于点 \mathbf{X} 到超平面的代数距离。



$$d(\mathbf{X}) = \mathbf{W}_0^T \mathbf{X} + w_{n+1}$$



X 到超平面的距离: $r = \frac{d(X)}{\|\mathbf{W}_0\|}$

——点 X 到超平面的代数距离（带正负号）正比于 $d(X)$ 函数值。

(3) X 在原点

$$d(\mathbf{X}) = \mathbf{W}_0^T \mathbf{X} + w_{n+1} = w_{n+1}$$

得

$$r_0 = \frac{w_{n+1}}{\|\mathbf{W}_0\|}$$

——超平面的位置由阈值权 w_{n+1} 决定:

$w_{n+1} > 0$ 时, 原点在超平面的正侧;

$w_{n+1} < 0$ 时, 原点在超平面负侧;

$w_{n+1} = 0$ 时, 超平面通过原点。



判别函数值的鉴别意义、权空间及解空间

此方程表示一超平面 π 。它有以下三个性质：

- (1) 系数矢量 $\vec{w}_0 = (w_1, w_2, \dots, w_n)'$ ，
是该平面的法矢量。
- (2) 判别函数 $d(\vec{x})$ 的绝对值正比于 \vec{x} 到超平面 $d(\vec{x}) = 0$ 的距离。
- (3) 判别函数值的正负表示出特征点位于哪个半空间中。




图 点面距离及界面的正负侧示意图

证明：系数矢量 $\vec{w}_0 = (w_1, w_2, \dots, w_n)'$ ，是该平面的法矢量，即 $\vec{w}_0 \perp$ 平面 π 。

设点 \vec{x}_1 、 \vec{x}_2 在判别界面中，故它们满足方程，于是有

$$\vec{w}_0' \vec{x}_1 + w_{n+1} = 0$$

$$\vec{w}_0' \vec{x}_2 + w_{n+1} = 0$$

上面二式相减，可得： $\vec{w}_0' (\vec{x}_1 - \vec{x}_2) = 0$

这就表明： $\vec{w}_0 \perp (\vec{x}_1 - \vec{x}_2)$

而差矢量 $(\vec{x}_1 - \vec{x}_2)$ 在判别界面中，由于 \vec{x}_1 、 \vec{x}_2 是 π 中的任意两点，故 $\vec{w}_0 \perp$ 平面 π 。


证明：判别函数 $d(\vec{x})$ 的绝对值正比于 \vec{x} 到超平面 $d(\vec{x})=0$ 的距离。


平面 π 的方程可以写成：
$$\frac{\vec{w}'_0}{\|\vec{w}_0\|} \vec{x} = \frac{-w_{n+1}}{\|\vec{w}_0\|}$$

设平面 π 的单位法矢量 $\vec{n} \triangleq \frac{\vec{w}'_0}{\|\vec{w}_0\|}$ ，上式可写成 $\vec{n}'\vec{x} = \frac{-w_{n+1}}{\|\vec{w}_0\|}$

设 \vec{p} 是平面 π 中的任意一点， \vec{x} 是特征空间 X^n 中任一点，点 \vec{x} 到平面 π 的距离为差矢量 $(\vec{x} - \vec{p})$ 在 \vec{n} 上的投影的绝对值，即

$$d_x = |\vec{n}'(\vec{x} - \vec{p})| = |\vec{n}'\vec{x} - \vec{n}'\vec{p}|$$





$$\begin{aligned}
 d_x &= |\vec{n}'(\vec{x} - \vec{p})| = |\vec{n}'\vec{x} - \vec{n}'\vec{p}| \\
 &= \left| \frac{\vec{w}'_0}{\|\vec{w}_0\|} \vec{x} - \frac{\vec{w}'_0}{\|\vec{w}_0\|} \vec{p} \right| = \left| \frac{\vec{w}'_0}{\|\vec{w}_0\|} \vec{x} + \frac{w_{n+1}}{\|\vec{w}_0\|} \right| \\
 &= \frac{|\vec{w}'_0 \vec{x} + w_{n+1}|}{\|\vec{w}_0\|} = \frac{1}{\|\vec{w}_0\|} |d(\vec{x})|
 \end{aligned}$$

上式表明, $d(\vec{x})$ 的值 $|d(\vec{x})|$ 正比于 \vec{x} 到超平面 $d(\vec{x})=0$ 的距离 d_x 。



证明：判别函数值的正负表示出特征点位于哪个半空间中。


两矢量 \vec{n} 和 $(\vec{x} - \vec{p})$ 的数积为：

$$\vec{n}'(\vec{x} - \vec{p}) = \|\vec{n}\| \|\vec{x} - \vec{p}\| \cos(\vec{n}, (\vec{x} - \vec{p})) = \frac{\vec{w}_0' \vec{x} + w_{n+1}}{\|\vec{w}_0\|}$$

当 \vec{n} 和 $(\vec{x} - \vec{p})$ 夹角小于 90° 时，即 \vec{x} 在 \vec{n} 指向的那个半空间中， $\cos(\vec{n}, (\vec{x} - \vec{p})) > 0$ ；

反之，当 \vec{n} 和 $(\vec{x} - \vec{p})$ 夹角大于 90° 时，即 \vec{x} 在 \vec{n} 背向的半空间中， $\cos(\vec{n}, (\vec{x} - \vec{p})) < 0$ 。

由于 $\|\vec{w}_0\| > 0$ ，故 $\vec{n}'(\vec{x} - \vec{p})$ 和 $\vec{w}_0' \vec{x} + w_{n+1}$ 同号。



由于 $\|\vec{w}_0\| > 0$, 故 $\vec{n}'(\vec{x} - \vec{p})$ 和 $\vec{w}_0'\vec{x} + w_{n+1}$ 同号。

即 \vec{x} 在 \vec{n} 指向的半空间中时, $\vec{w}_0'\vec{x} + w_{n+1} > 0$

当 \vec{x} 在 \vec{n} 背向的半空间中时, $\vec{w}_0'\vec{x} + w_{n+1} < 0$

这说明判别函数值的正负表示出特征点位于哪个半空间中, 或者换句话说, 表示特征点位于界面的哪一侧。

4.4 广义线性判别函数

- 以下情况不能使用线性判别函数。

$$\begin{cases} x < b \text{ 或 } x > a, & x \in \omega_1 \\ b < x < a, & x \in \omega_2 \end{cases}$$

- 要达到分类效果，需要设计这样的判别函数：

$$d(x) = (x-a)(x-b)$$

- 决策规则为：

$$\begin{cases} d(x) > 0, & x \in \omega_1 \\ d(x) < 0, & x \in \omega_2 \end{cases}$$

4.4 广义线性判别函数

目的:

对非线性边界：通过某映射，把模式空间 X 变成 X^* ，以便将 X 空间中非线性可分的模式集，变成在 X^* 空间中线性可分的模式集。

1. 非线性多项式函数

$$d(\mathbf{X}) = w_1x_1 + w_2x_2 + \dots + w_nx_n + w_{n+1}$$

非线性判别函数的形式之一是非线性多项式函数。

设一训练用模式集， $\{\mathbf{X}\}$ 在模式空间 X 中线性不可分，非线性判别函数形式如下：

$$d(\mathbf{X}) = w_1f_1(\mathbf{X}) + w_2f_2(\mathbf{X}) + \dots + w_kf_k(\mathbf{X}) + w_{k+1} = \sum_{i=1}^{k+1} w_i f_i(\mathbf{X})$$

式中 $\{f_i(\mathbf{X}), i=1,2,\dots,k\}$ 是模式 \mathbf{X} 的单值实函数， $f_{k+1}(\mathbf{X})=1$ 。

$f_i(\mathbf{X})$ 取什么形式及 $d(\mathbf{X})$ 取多少项，取决于非线性边界的复杂程度。



广义形式的模式向量定义为：

$$\mathbf{X}^* = [x_1^*, x_2^*, \dots, x_k^*, 1]^T = [f_1(\mathbf{X}), f_2(\mathbf{X}), \dots, f_k(\mathbf{X}), 1]^T$$

这里 \mathbf{X}^* 空间的维数 k 高于 \mathbf{X} 空间的维数 n ，上式可写为

$$d(\mathbf{X}) = \mathbf{W}^T \mathbf{X}^* = d(\mathbf{X}^*), \quad \mathbf{W} = [w_1, w_2, \dots, w_k, w_{k+1}]^T$$

上式是线性的。讨论线性判别函数并不会失去一般性的意义。

问题：

非线性变换可能非常复杂。

维数大大增加： 维数灾难。



假设 \mathbf{X} 为二维模式向量, $f_i(\mathbf{X})$ 选用二次多项式函数, 原判别函数为 $d(\mathbf{X}) = w_{11}x_1^2 + w_{12}x_1x_2 + w_{22}x_2^2 + w_1x_1 + w_2x_2 + w_3$
广义线性判别函数:

定义: $x^*_1 = f_1(\mathbf{X}) = x_1^2$ $x^*_2 = f_2(\mathbf{X}) = x_1x_2$

$$x^*_3 = f_3(\mathbf{X}) = x_2^2 \quad x^*_4 = f_4(\mathbf{X}) = x_1 \quad x^*_5 = f_5(\mathbf{X}) = x_2$$

即: $\mathbf{X}^* = [x_1^2, x_1x_2, x_2^2, x_1, x_2, 1]^T$ $\mathbf{W} = [w_{11}, w_{12}, w_{22}, w_1, w_2, w_3]^T$

$d(\mathbf{X})$ 线性化为: $d(\mathbf{X}^*) = \mathbf{W}^T \mathbf{X}^*$

4.5 广义线性判别函数举例

例：有一个三次判别函数： $z=g(x)=x^3+2x^2+3x+4$ 。试建立一映射 $x \rightarrow \mathbf{y}$ ，使得 z 转化为 \mathbf{y} 的线性判别函数。

答：映射 $\mathbf{X} \rightarrow \mathbf{Y}$ 如下：

$$\mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ y_3 \\ y_4 \end{bmatrix} = \begin{bmatrix} 1 \\ x \\ x^2 \\ x^3 \end{bmatrix}, \quad \mathbf{a} = \begin{bmatrix} a_1 \\ a_2 \\ a_3 \\ a_4 \end{bmatrix} = \begin{bmatrix} 4 \\ 3 \\ 2 \\ 1 \end{bmatrix}$$

$$z = g(x) = h(\mathbf{y}) = \mathbf{a}^T \mathbf{y} = \sum_{i=1}^4 a_i y_i$$

4.5 广义线性判别函数举例

例：设在三维空间中一个类别分类问题拟采用二次曲面。如欲采用广义线性方程求解，试问其广义样本向量与广义权向量的表达式，其维数是多少？

答：设二次曲面为：

二次
曲面

$$ax_1^2 + bx_2^2 + cx_3^2 + dx_1x_2 + ex_1x_3 + fx_2x_3 + gx_1 + hx_2 + lx_3 + m = 0$$

广义
权向量

$$\mathbf{a} = (a, b, c, d, e, f, g, h, l, m)^T$$

广义样
本向量

$$\mathbf{y} = (x_1^2, x_2^2, x_3^2, x_1x_2, x_1x_3, x_2x_3, x_1, x_2, x_3, 1)^T$$

维数为10

$$z = g(\mathbf{x}) = h(\mathbf{y}) = \mathbf{a}^T \mathbf{y}$$

广义线性
判别函数


4.6 感知器算法 (perception approach)

对一种分类学习机模型的称呼，属于有关机器学习的仿生学领域中的问题，由于无法实现非线性分类而下马。但“赏罚概念 (reward-punishment concept)” 得到广泛应用。

两类线性可分的模式类： ω_1, ω_2 ，设 $d(\mathbf{X}) = \mathbf{W}^T \mathbf{X}$

其中， $\mathbf{W} = [w_1, w_2, \dots, w_n, w_{n+1}]^T$ ， $\mathbf{X} = [x_1, x_2, \dots, x_n, 1]^T$

应具有性质 $d(\mathbf{X}) = \mathbf{W}^T \mathbf{X} \begin{cases} > 0, & \text{若 } \mathbf{X} \in \omega_1 \\ < 0, & \text{若 } \mathbf{X} \in \omega_2 \end{cases}$



对样本进行规范化处理，即 ω_2 类样本全部乘以 (-1) ，则有：

$$d(\mathbf{X}) = \mathbf{W}^T \mathbf{X} > 0$$

感知器算法通过对已知类别的训练样本集的学习，寻找一个满足上式的权向量。

感知器算法步骤：


(1) 选择 N 个分属于 ω_1 和 ω_2 类的模式样本构成训练样本集

$$\{ \mathbf{X}_1, \dots, \mathbf{X}_N \}$$

构成增广向量形式，并进行规范化处理。任取权向量初始值 $\mathbf{W}(1)$ ，开始迭代。迭代次数 $k=1$ 。

(2) 用全部训练样本进行一轮迭代，计算 $\mathbf{W}^T(k)\mathbf{X}_i$ 的值，并修正权向量。

分两种情况，更新权向量的值：



① 若 $\mathbf{W}^T(k)\mathbf{X}_i \leq 0$, 分类器对第 i 个模式做了错误分类,

权向量校正为: $\mathbf{W}(k+1) = \mathbf{W}(k) + c\mathbf{X}_i$

c : 正的校正增量。

② 若 $\mathbf{W}^T(k)\mathbf{X}_i > 0$, 分类正确, 权向量不变:

$$\mathbf{W}(k+1) = \mathbf{W}(k)$$

统一写为:

$$\mathbf{W}(k+1) = \begin{cases} \mathbf{W}(k) & \text{若 } \mathbf{W}^T(k)\mathbf{X}_i > 0 \\ \mathbf{W}(k) + c\mathbf{X}_i & \text{若 } \mathbf{W}^T(k)\mathbf{X}_i \leq 0 \end{cases}$$

(3) 分析分类结果: 只要有一个错误分类, 回到 (2), 直至对所有样本正确分类。

梯度法

1. 梯度概念

函数在某点的梯度是这样—一个向量，它的方向与取得最大方向导数的方向一致,而它的模为方向导数的最大值. 记为:



$$\nabla f(\mathbf{Y}) = \frac{d}{d\mathbf{Y}} f(\mathbf{Y}) = \left[\frac{\partial f}{\partial y_1}, \frac{\partial f}{\partial y_2}, \dots, \frac{\partial f}{\partial y_n} \right]^T$$

即:

梯度的**方向**是函数 $f(\mathbf{Y})$ 在 \mathbf{Y} 点增长最快的方向,

梯度的**模**是 $f(\mathbf{Y})$ 在增长最快的方向上的增长率 (增长率最大值)。


显然: **负梯度指出了最陡下降方向**。——梯度算法的依据。



梯度示例：

上面两个图中，标量场是黑白的，黑色表示大的数值，而其相应的梯度用蓝色箭头表示。

(<http://zh.wikipedia.org/wiki/%E6%A2%AF%E5%BA%A6>)



梯度算法

设两个线性可分的模式类 ω_1 和 ω_2 的样本共 N 个， ω_2 类样本乘(-1)。将两类样本分开的判决函数 $d(\mathbf{X})$ 应满足：

$$d(\mathbf{X}_i) = \mathbf{W}^T \mathbf{X}_i > 0 \quad i = 1, 2, \dots, N \quad \text{——} N \text{个不等式}$$

梯度算法的目的仍然是求一个满足上述条件的权向量，**主导思想是将联立不等式求解 \mathbf{W} 的问题，转换成求准则函数极小值的问题。**

用负梯度向量的值对权向量 \mathbf{W} 进行修正，实现使准则函数达到极小值的目的。

准则函数的选取原则：

具有唯一的最小值，并且这个最小值发生在 $\mathbf{W}^T \mathbf{X}_i > 0$ 时。

基本思路:

定义一个对错误分类敏感的准则函数 $J(\mathbf{W}, \mathbf{X})$, 在 J 的梯度方向上对权向量进行修改。一般关系表示成从 $\mathbf{W}(k)$ 导出 $\mathbf{W}(k+1)$:

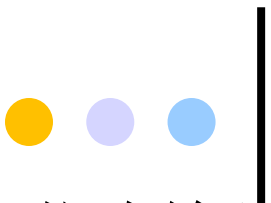
$$\mathbf{W}(k+1) = \mathbf{W}(k) + c(-\nabla J) = \mathbf{W}(k) - c\nabla J$$

$$\mathbf{W}(k+1) = \mathbf{W}(k) - c \left[\frac{\partial J(\mathbf{W}, \mathbf{X})}{\partial \mathbf{W}} \right]_{\mathbf{W}=\mathbf{W}(k)}$$

其中 c 是正的比例因子。

梯度法求解步骤:

(1) 将样本写成规范化增广向量形式, 选择准则函数, 设置初始权向量 $\mathbf{W}(1)$, 括号内为迭代次数 $k=1$ 。



依次输入训练样本 \mathbf{X} 。设第 k 次迭代时输入样本为 \mathbf{X}_i ，此时
已有权向量 $\mathbf{W}(k)$ ，求 $\nabla J(k)$ ：

$$\nabla J(k) = \left. \frac{\partial J(\mathbf{W}, \mathbf{X}_i)}{\partial \mathbf{W}} \right|_{\mathbf{W} = \mathbf{W}(k)}$$

权向量修正为：

$$\mathbf{W}(k+1) = \mathbf{W}(k) - c \nabla J(k)$$

迭代次数 k 加1，输入下一个训练样本，计算新的权向量，直至
对全部训练样本完成一轮迭代。

(3) 在一轮迭代中，如果有一个样本使 $\nabla J \neq 0$ ，回到(2)进行下一轮迭代。否则， \mathbf{W} 不再变化，算法收敛。

a)

说明:

$$\mathbf{W}(k+1) = \mathbf{W}(k) - c \nabla J = \mathbf{W}(k) - c \left[\frac{\partial J(\mathbf{W}, \mathbf{X})}{\partial \mathbf{W}} \right]_{\mathbf{W}=\mathbf{W}(k)}$$

随着权向量 \mathbf{W} 向理想值接近, 准则函数关于 \mathbf{W} 的导数 (∇J) 越来越趋近于零, 这意味着准则函数 J 越来越接近最小值。当最终 $\nabla J = 0$ 时, J 达到最小值, 此时 \mathbf{W} 不再改变, 算法收敛。

—— 将感知器算法中联立不等式求解 \mathbf{W} 的问题, 转换为求函数 J 极小值的问题。

b) c 值的选择很重要, 如 c 值太小, 收敛太慢; 但若太大, 搜索又可能过头, 甚至引起发散。

c) 梯度算法是求解权向量的一般解法, 算法的具体计算形式取决于准则函数 $J(\mathbf{W}, \mathbf{X})$ 的选择, $J(\mathbf{W}, \mathbf{X})$ 的形式不同, 得到的具体算法不同。

固定增量法

准则函数: $J(W, X) = \frac{1}{2} (|W^T X| - W^T X)$

该准则函数有唯一最小值“0”，且发生在 $W^T X > 0$ 的时候。

求 $W(k)$ 的递推公式:

设 $X = [x_1, x_2, \dots, x_n, 1]^T$, $W = [w_1, w_2, \dots, w_n, w_{n+1}]^T$

1. 求 J 的梯度 $\nabla J = \frac{\partial J(W, X)}{\partial W} = ?$

方法: 函数对向量求导=函数对向量的分量求导, 即

$$\frac{\partial f}{\partial X} = \left[\frac{\partial f}{\partial x_1}, \dots, \frac{\partial f}{\partial x_n} \right]^T$$



$$J(W, X) = \frac{1}{2} (\|W^T X\|^2 - W^T X)$$

①首先求 $W^T X$ 部分:

$$\begin{aligned}\frac{\partial(W^T X)}{\partial W} &= \frac{\partial}{\partial W} \left(\sum_{i=1}^n w_i x_i + w_{n+1} \right) \\ &= \left[\frac{\partial}{\partial w_1} \left(\sum_{i=1}^n w_i x_i + w_{n+1} \right), \dots, \frac{\partial}{\partial w_k} \left(\sum_{i=1}^n w_i x_i + w_{n+1} \right), \dots, \frac{\partial}{\partial w_{n+1}} \left(\sum_{i=1}^n w_i x_i + w_{n+1} \right) \right]^T \\ &= [x_1, \dots, x_k, \dots, x_n, 1]^T = X\end{aligned}$$

或: 矩阵论中有

$$\begin{aligned}\frac{dX}{dX^T} &= \frac{dX^T}{dX} = I_{n \times n} \\ \therefore \frac{\partial(W^T X)}{\partial W} &= I_{(n+1) \times (n+1)} X_{(n+1) \times 1} = X_{(n+1) \times 1}\end{aligned}$$

$$J(W, X) = \frac{1}{2} (|W^T X| - W^T X)$$

② 由①的结论 $\frac{\partial(W^T X)}{\partial W} = X$ 有:

$$W^T X > 0 \text{ 时, } \frac{\partial(|W^T X|)}{\partial W} = \frac{\partial(W^T X)}{\partial W} = X$$

$$W^T X \leq 0 \text{ 时, } \frac{\partial(|W^T X|)}{\partial W} = \frac{\partial(-W^T X)}{\partial W} = -X$$

$$\therefore \frac{\partial(|W^T X|)}{\partial W} = [\text{sgn}(W^T X)] \cdot X$$

$$\text{其中 } \text{sgn}(W^T X) = \begin{cases} +1, & \text{若 } W^T X > 0 \\ -1, & \text{若 } W^T X \leq 0 \end{cases}$$

$$\therefore \nabla J = \frac{\partial J(W, X)}{\partial W} = \frac{1}{2} [X \text{sgn}(W^T X) - X]$$



2. 求 $\mathbf{W}(k+1)$

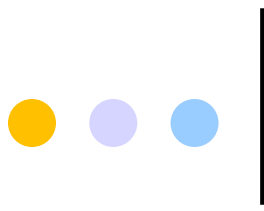
将 $\nabla J = \frac{\partial J(\mathbf{W}, \mathbf{X})}{\partial \mathbf{W}} = \frac{1}{2} [\mathbf{X} \operatorname{sgn}(\mathbf{W}^T \mathbf{X}) - \mathbf{X}]$ 代入

$$\mathbf{W}(k+1) = \mathbf{W}(k) - c \nabla J = \mathbf{W}(k) - c \left[\frac{\partial J(\mathbf{W}, \mathbf{X})}{\partial \mathbf{W}} \right]_{\mathbf{W}=\mathbf{W}(k)}$$

$$\text{得: } \mathbf{W}(k+1) = \mathbf{W}(k) - c \frac{1}{2} [\mathbf{X} \operatorname{sgn}(\mathbf{W}^T(k) \mathbf{X}) - \mathbf{X}]$$

$$= \mathbf{W}(k) + \frac{c}{2} [\mathbf{X} - \mathbf{X} \operatorname{sgn}(\mathbf{W}^T(k) \mathbf{X})]$$

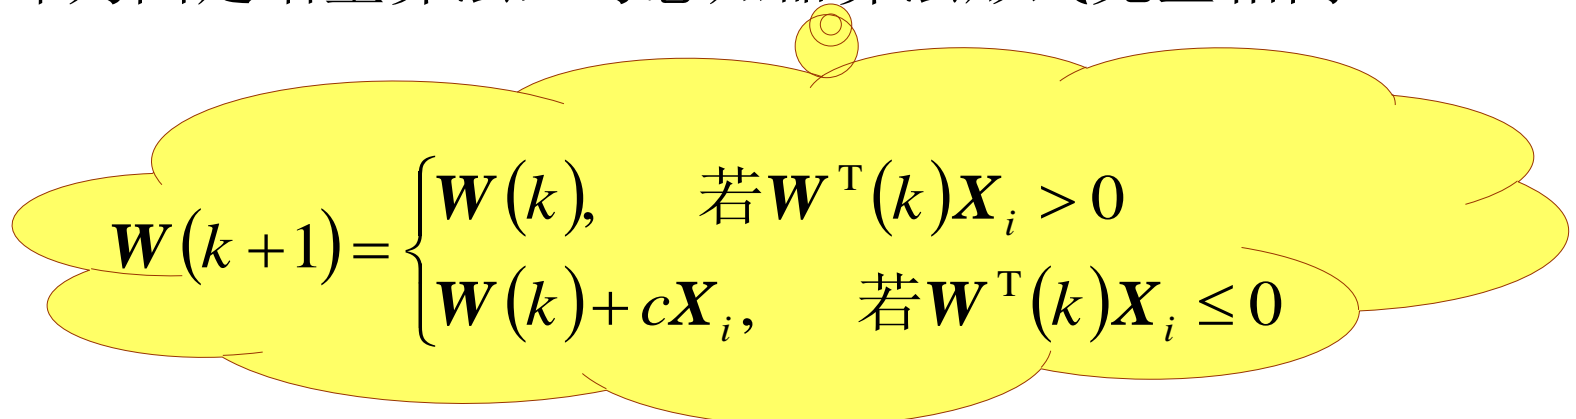
$$= \mathbf{W}(k) + \begin{cases} 0, & \text{若 } \mathbf{W}^T(k) \mathbf{X} > 0 \\ c\mathbf{X}, & \text{若 } \mathbf{W}^T(k) \mathbf{X} \leq 0 \end{cases}$$



即：

$$\mathbf{W}(k+1) = \mathbf{W}(k) + \begin{cases} 0, & \text{若 } \mathbf{W}^T(k)\mathbf{X} > 0 \\ c\mathbf{X}, & \text{若 } \mathbf{W}^T(k)\mathbf{X} \leq 0 \end{cases}$$


上式即为固定增量算法，与感知器算法形式完全相同。


$$\mathbf{W}(k+1) = \begin{cases} \mathbf{W}(k), & \text{若 } \mathbf{W}^T(k)\mathbf{X}_i > 0 \\ \mathbf{W}(k) + c\mathbf{X}_i, & \text{若 } \mathbf{W}^T(k)\mathbf{X}_i \leq 0 \end{cases}$$

由此可以看出，感知器算法是梯度法的特例。即：梯度法是将感知器算法中联立不等式求解 \mathbf{W} 的问题，转换为求函数 J 极小值的问题，将原来有多个解的情况，变成求最优解的情况。


只要模式类是线性可分的，算法就会给出解。

感知器算法的几何解释




理想的分界面

感知器算法的几何解释



一次迭代过程中的分界面

感知器算法的几何解释



对分界面法线向量的调整



最小平方误差算法

(least mean square error, LMSE;)

上述的感知器算法、梯度算法、固定增量算法或其他类似方法，只有当模式类可分离时才收敛，在不可分的情况下，算法会来回摆动，始终不收敛。当一次次迭代而又不见收敛时，造成不收敛现象的原因分不清，有两种可能：

- a) 迭代过程本身收敛缓慢
- b) 模式本身不可分

LMSE算法特点：

对可分模式收敛。

对于类别不可分的情况也能指出来。

LMSE算法

1) 原理 LMSE算法把对满足 $XW > 0$ 的求解, 改为满足

$$XW = B$$

的求解。式中:

$B = [b_1, b_2, \dots, b_i, \dots, b_N]^T$ 为各分量均为正值的矢量。

说明:

\therefore 两式等价。

① 在方程组中当行数 \gg 列数时, 通常无解, 称为矛盾方程组, 一般求近似解。在模式识别中, 通常训练样本数 N 总是大于模式的维数 n , 因此方程的个数(行数) \gg 模式向量的维数(列数), 是矛盾方程组, 只能求近似解 W^* , 即

$$\|XW^* - B\| = \text{极小}$$

补充: LMSE一般指 B 固定, 当 B 可变时称为Ho-Kashyap算法。

分类器的不等式方程

两类分类问题的解相当于求一组线性不等式的解。如果给出分属于 ω_1 , ω_2 两个模式类的训练样本集 $\{\mathbf{X}_i, i=1,2,\dots,N\}$, 应满足:

$$\mathbf{W}^T \mathbf{X}_i > 0$$

其中, \mathbf{X}_i 是规范化增广样本向量, $\mathbf{X}_i = [x_{i1}, x_{i2}, \dots, x_{in}, 1]^T$ 。

上式分开写为:

$$\begin{array}{l} \omega_1 \text{类} \\ \hline \omega_2 \text{类} \end{array} \left\{ \begin{array}{ll} w_1 x_{11} + w_2 x_{12} + \dots + w_n x_{1n} + w_{n+1} > 0 & \text{对 } \mathbf{X}_1 \\ w_1 x_{21} + w_2 x_{22} + \dots + w_n x_{2n} + w_{n+1} > 0 & \text{对 } \mathbf{X}_2 \\ \vdots & \\ -w_1 x_{N1} - w_2 x_{N2} - \dots - w_n x_{Nn} - w_{n+1} > 0 & \text{对 } \mathbf{X}_N \end{array} \right.$$

ω_1 类

ω_2 类

$$\begin{cases} w_1 x_{11} + w_2 x_{12} + \cdots + w_n x_{1n} + w_{n+1} > 0 & \text{对 } \mathbf{X}_1 \\ w_1 x_{21} + w_2 x_{22} + \cdots + w_n x_{2n} + w_{n+1} > 0 & \text{对 } \mathbf{X}_2 \\ \vdots & \\ -w_1 x_{N1} - w_2 x_{N2} - \cdots - w_n x_{Nn} - w_{n+1} > 0 & \text{对 } \mathbf{X}_N \end{cases}$$

写成矩阵形式为：

$$\begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1n} & 1 \\ x_{21} & x_{22} & \cdots & x_{2n} & 1 \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ -x_{N1} & -x_{N2} & \cdots & -x_{Nn} & -1 \end{bmatrix}_{N \times (n+1)} \begin{bmatrix} w_1 \\ w_2 \\ \vdots \\ w_n \\ w_{n+1} \end{bmatrix}_{(n+1) \times 1} > \begin{bmatrix} 0 \\ 0 \\ \vdots \\ 0 \\ 0 \end{bmatrix}_{N \times 1} = \mathbf{0}$$

令 $N \times (n+1)$ 的长方矩阵为 \mathbf{X} ，则 $\mathbf{W}^T \mathbf{X}_i > 0$ 变为：

$$\mathbf{XW} > \mathbf{0}$$



$$\left| \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1n} & 1 \\ x_{21} & x_{22} & \cdots & x_{2n} & 1 \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ -x_{N1} & -x_{N2} & \cdots & -x_{Nn} & -1 \end{bmatrix}_{N \times (n+1)} \begin{bmatrix} w_1 \\ w_2 \\ \vdots \\ w_n \\ w_{n+1} \end{bmatrix}_{(n+1) \times 1} > \begin{bmatrix} 0 \\ 0 \\ \vdots \\ 0 \\ 0 \end{bmatrix}_{N \times 1} = \mathbf{0}$$

式中: $XW > \mathbf{0}$

$$X = \left[\begin{array}{c} \mathbf{X}_1^T \\ \mathbf{X}_2^T \\ \vdots \\ \mathbf{X}_i^T \\ \vdots \\ -\mathbf{X}_{N-1}^T \\ -\mathbf{X}_N^T \end{array} \right]_{N \times (n+1)} \left\{ \begin{array}{l} \in \omega_1 \\ \hline \in \omega_2 \end{array} \right.$$

$$W = [w_1, w_2, \cdots, w_n, w_{n+1}]^T$$

$\mathbf{0}$ 为零向量

感知器算法是通过解不等式组 $XW > \mathbf{0}$ ，求出 W 。

② LMSE算法的出发点：选择一个准则函数，使得当 J 达到最小值时， $\mathbf{XW}=\mathbf{B}$ 可得到近似解（最小二乘近似解）。

准则函数定义为：

“最小二乘”：
$$J(\mathbf{W}, \mathbf{X}, \mathbf{B}) = \frac{1}{2} \|\mathbf{XW} - \mathbf{B}\|^2$$

—— 最小：使方程组两边误差最小，
也即使 J 最小。
—— 二乘：次数为2

} 最小平方（误差算法）

③ LMSE算法的思路：对 $\mathbf{XW} > \mathbf{0}$ 求解

转化为

对 $\mathbf{XW} = \mathbf{B}$ 求解

转化为

通过求准则函数极小找 \mathbf{W} 、 \mathbf{B}

考察向量 $(XW - B)$ 有：

$$XW - B = \begin{bmatrix} x_{11} & \cdots & x_{1n} & 1 \\ x_{21} & \cdots & x_{2n} & 1 \\ \vdots & \cdots & \vdots & 1 \\ x_{i1} & \cdots & x_{in} & 1 \\ \vdots & \cdots & \vdots & 1 \\ -x_{N1} & \cdots & -x_{Nn} & 1 \end{bmatrix}_{N \times (n+1)} \begin{bmatrix} w_1 \\ w_2 \\ \vdots \\ w_n \\ w_{n+1} \end{bmatrix}_{(n+1) \times 1} - \begin{bmatrix} b_1 \\ \vdots \\ b_i \\ \vdots \\ b_N \end{bmatrix}_{N \times 1}$$

$$= \begin{bmatrix} x_{11}w_1 + \cdots + x_{1n}w_n + w_{n+1} - b_1 \\ \vdots \\ x_{i1}w_1 + \cdots + x_{in}w_n + w_{n+1} - b_i \\ \vdots \\ -x_{N1}w_1 - \cdots - x_{Nn}w_n - w_{n+1} - b_N \end{bmatrix}_{N \times 1} = \begin{bmatrix} \mathbf{W}^T \mathbf{X}_1 - b_1 \\ \vdots \\ \mathbf{W}^T \mathbf{X}_i - b_i \\ \vdots \\ \mathbf{W}^T \mathbf{X}_N - b_N \end{bmatrix}$$

$$\begin{aligned} \|\mathbf{XW} - \mathbf{B}\|^2 &= \left(\sqrt{\text{向量各分量的平方和}} \right)^2 = \text{向量各分量的平方和} \\ \|\mathbf{XW} - \mathbf{B}\|^2 &= (\mathbf{W}^T \mathbf{X}_1 - b_1)^2 + \cdots + (\mathbf{W}^T \mathbf{X}_N - b_N)^2 = \sum_{i=1}^N (\mathbf{W}^T \mathbf{X}_i - b_i)^2 \end{aligned}$$

● ● ● | 准则函数:

$$J(\mathbf{W}, \mathbf{X}, \mathbf{B}) = \frac{1}{2} \|\mathbf{XW} - \mathbf{B}\|^2 = \frac{1}{2} \sum_{i=1}^N (\mathbf{W}^T \mathbf{X}_i - b_i)^2$$

$\mathbf{XW}=\mathbf{B}$ 的近似解也称“最优近似解”:

——使方程组两边所有误差之和最小（即最优）的解。

可以看出:

① 当函数 J 达到最小值, 等式 $\mathbf{XW}=\mathbf{B}$ 有最优解。即又将问题转化为求准则函数极小值的问题。

② 因为 J 有两个变量 \mathbf{W} 和 \mathbf{B} , 有更多的自由度供选择求解, 故可望改善算法的收敛速率。

2) 推导LMSE算法递推公式

与问题相关的两个梯度：

$$\frac{\partial J}{\partial \mathbf{W}} = \mathbf{X}^T (\mathbf{XW} - \mathbf{B})$$

$$\frac{\partial J}{\partial \mathbf{B}} = -\frac{1}{2} [(\mathbf{XW} - \mathbf{B}) + |\mathbf{XW} - \mathbf{B}|]$$

求递推公式：

(1) 求 \mathbf{W} 的递推关系

使 J 对 \mathbf{W} 求最小，令 $\frac{\partial J}{\partial \mathbf{W}} = 0$ ，得：

$$\mathbf{X}^T (\mathbf{XW} - \mathbf{B}) = 0 \Rightarrow \mathbf{X}^T \mathbf{XW} = \mathbf{X}^T \mathbf{B} \Rightarrow \mathbf{W} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{B} = \mathbf{X}^\# \mathbf{B}$$

式中： $\mathbf{X}^\# = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T$ 称为 \mathbf{X} 的伪逆，也称为广义逆阵。

\mathbf{X} 为 $N \times (n+1)$ 长方阵， $\mathbf{X}^\#$ 为 $(n+1) \times N$ 长方阵。

由上式可知：只要求出 \mathbf{B} ，就可求出 \mathbf{W} 。

$$\frac{\partial J}{\partial \mathbf{B}} = -\frac{1}{2}[(\mathbf{XW} - \mathbf{B}) + |\mathbf{XW} - \mathbf{B}|]$$

(2) 求 $\mathbf{B}(k+1)$ 的迭代式

利用梯度算法公式 $\mathbf{W}(k+1) = \mathbf{W}(k) - c \left[\frac{\partial J(\mathbf{W}, \mathbf{X})}{\partial \mathbf{W}} \right]_{\mathbf{W}=\mathbf{W}(k)}$ 有：

$$\mathbf{B}(k+1) = \mathbf{B}(k) - c' \left[\frac{\partial J}{\partial \mathbf{B}} \right]_{\mathbf{B}=\mathbf{B}(k)}$$

代入，得

$$\mathbf{B}(k+1) = \mathbf{B}(k) + \frac{c'}{2} [(\mathbf{XW}(k) - \mathbf{B}(k)) + |\mathbf{XW}(k) - \mathbf{B}(k)|]$$

令 $c'/2 = c$ ，定义 $\mathbf{XW}(k) - \mathbf{B}(k) = \mathbf{e}(k)$

$$\mathbf{B}(k+1) = \mathbf{B}(k) + c[\mathbf{e}(k) + |\mathbf{e}(k)|]$$

(3) 求 $\mathbf{W}(k+1)$ 的迭代式

$$\begin{aligned}\mathbf{W}(k+1) &= \mathbf{X}^\# \mathbf{B}(k+1) = \mathbf{X}^\# \{ \mathbf{B}(k) + c[\mathbf{e}(k) + |\mathbf{e}(k)|] \} \\ &= \mathbf{X}^\# \mathbf{B}(k) + \mathbf{X}^\# c \mathbf{e}(k) + \mathbf{X}^\# c |\mathbf{e}(k)| = \mathbf{W}(k) + c \mathbf{X}^\# |\mathbf{e}(k)|\end{aligned}$$

$=0$

$$\begin{aligned}\mathbf{X}^\# \mathbf{e}(k) &= (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top [\mathbf{X} \mathbf{W}(k) - \mathbf{B}(k)] \\ &= \mathbf{W}(k) - \mathbf{X}^\# \mathbf{B}(k) = 0\end{aligned}$$

$$\mathbf{B}(k+1) = \mathbf{B}(k) + c[\mathbf{e}(k) + |\mathbf{e}(k)|]$$

$$\mathbf{X} \mathbf{W}(k) - \mathbf{B}(k) = \mathbf{e}(k)$$

总结：设初值 $B(1)$ ，各分量均为正值，括号中数字代表迭代次数。

$$W(1) = X^{\#} B(1)$$

$$e(k) = XW(k) - B(k)$$

$$W(k+1) = W(k) + cX^{\#}|e(k)|$$

$$B(k+1) = B(k) + c[e(k) + |e(k)|]$$

$W(k+1)$ 、 $B(k+1)$ 计算的先后次序无关。

或另一算法：先算 $B(k+1)$ ，再算 $W(k+1)$ 。

$$W(1) = X^{\#} B(1)$$

$$\dots$$
$$e(k) = XW(k) - B(k)$$

$$B(k+1) = B(k) + c[e(k) + |e(k)|]$$

$$W(k+1) = X^{\#} B(k+1)$$

求出 B ， W 后，再迭代出下一个 e ，从而计算出新的 B ， W 。